Clustering konsumsi Listrik Setiap Provinsi di Indonesia

Jefferson Darren Cendres-2702256340
Revel Cahyadi-2702241484
Antonius Sebastian Gunadi - 2702248824

A. Problem Background

Pada zaman sekarang, semua kegiatan akan secara tidak langsung bergantung pada pemakaian listrik, seperti penggunaan kulkas untuk menyimpan makanan atau menggunakan lampu untuk menerangi ruang belajar. Oleh karena itu pengguna listrik akan semakin meningkat seiring dengan kebutuhan hidup sehari-hari. Berdasarkan tren yang ada di Indonesia, tercatat bahwa konsumsi listrik per kapita terus meningkat sejak tahun 2017, hal ini menunjukan bahwa perlunya strategi yang lebih baik dalam mengelola dan mendistribusikan listrik di setiap wilayah. Salah satu caranya yaitu melihat serta memahami pola konsumsi di setiap provinsinya dengan menerapkan metode clustering. Tentunya setiap wilayah memiliki tingkat konsumsi listrik yang berbeda-beda dapat dilihat dari seberapa besar penduduknya dan kawasan industri atau bukan. Sehingga perlu melakukan analisis dengan melakukan pengelompokan provinsi berdasarkan pola konsumsi listriknya sehingga nantinya dapat diidentifikasi kelompok provinsi dengan karakteristik penggunaan yang serupa. Setelah melakukan analisis ini diharapkan dapat membantu perencanaan distribusi listrik yang lebih efisien dengan memastikan ketersediaan energi yang optimal sesuai dengan kebutuhan setiap masing-masing daerah. Karena saat ini distribusi listrik masih berbasis pada perkiraan konsumsi historis tanpa melakukan analisis yang lebih mendalam terhadap pola penggunaan di setiap provinsi yang akan membuat pemborosan energi atau kekurangan pasokan energi di beberapa daerah.

B. Literature Review

- **Paper 1 (ANALISIS PENGGUNAAN LISTRIK PLN DI JAWA TIMUR MENGGUNAKAN ALGORITMA K-MEDOIDS)**
  Pada penelitian ini mereka melakukan analisis dalam pola penggunaan listrik di Jawa Timur berdasarkan data PLN dari BPS 2019-2021. Pada penelitian ini juga memiliki tujuan yaitu melakukan analisis dan hasilnya itu agar menjadi perencanaan pasokan di masa depan secara efektif. Mereka menggunakan dataset Jumlah Produksi Listrik, Jumlah Daya Listrik Terpasang, Jumlah Daya Listrik

Terjual, dan Jumlah Pelanggan Listrik. Metode yang mereka gunakan adalah metode clustering yang dimana mereka mengelompokkan dibagi menjadi 3 cluster sesuai penggunaannya, yaitu cluster rendah, cluster sedang, dan cluster tinggi, kemudian setelah melakukan pembangunan model, mereka akan melakukan evaluasi. Mereka menggunakan model K-Medoids, dikarenakan model ini lebih tahan terhadap outlier dibandingkan K-Means. Mereka melakukan eksperimen dengan menggunakan RapidMiner.

Hasil yang didapat adalah

- klaster 0 (rendah) terdapat 23 data UP
- klaster 1 (tinggi) terdapat 2 data UP
- klaster 2 (sedang) terdapat 25 data UP.

Dari hasil analisis menunjukkan

- UP3 Situbondo (2019) masuk ke klaster rendah untuk indikator produksi listrik, daya listrik terjual, dan daya listrik terpasang.
- UP Gabungan (2020-2021) masuk ke klaster tinggi untuk indikator produksi listrik, daya listrik terjual, daya lustrik terpasang, dan jumlah pelanggan listrik.
- UP3 Surabaya (2019) masuk ke kelaster terendah untuk indikator jumlah pelanggan listrik.

Untuk itu, kelompok kami memutuskan untuk memilih K-Medoids sebagai salah satu metode yang akan diuji karena dataset kelompok kami memiliki outlier, sehingga kami mengharapkan K-Medoids bisa menjadi model yang optimal dalam menganalisis dataset yang kami miliki.

- **Paper 2 (Pengelompokkan Data Pendistribusian Listrik Menggunakan Algoritma Mini Batch K-Means Clustering)**

  Penelitian ini juga memiliki tujuan dalam menganalisis pola distribusi listrik di Indonesia antar provinsi (35 provinsi) dengan menggunakan data tahun 2014-2022 yang diharapkan membawa manfaat dan hasil yang dapat memastikan pasokan listrik stabil bagi masyarakat dan pemerintah. Data yang mereka gunakan bersumber dari Statistik PLN berdasarkan Rumah Tangga, Industri, Bisnis, SOsial, Gedung Pemerintah, Jalan Umum. Mereka melakukan preprocessing dengan membagi menjadi per label berdasarkan letak geografis yang dimana :

  - Sumatera, meliputi: Aceh, Sumut, Sumbar, Riau, Kepri, Batam, Jambi, Bengkulu, Sumsel, Babel, dan Lampung (11 wilayah).
  - Jawa-Bali, meliputi: Banten, DKI/Tangerang, Jabar, Jateng, Jatim, DIY, Bali, NTB dan NTT (9 wilayah)
  - Kalimantan-Sulawesi, meliputi: Kalbar, Kalteng, Kaltim/Kaltara, Kalsel, Sulut, Gorontalo, Tarakan, Sulbar, Sulsel, Sulteng, Sultra, Malut, dan Maluku (13 wilayah)

- Papua

Namun, yang akan digunakan nantinya hanya 3 regional yaitu Sumatera, Jawa-Bali, dan Kalimantan Sulawesi. Setelah itu, dilakukan pembangunan model menggunakan Mini Batch K-Means menggunakan 2 pusat centroid. Setelah itu, n dilakukan evaluasi model menggunakan Silhouette Score (dengan membandingkan k=2,3,4). Hasil yang didapat berdasarkan Silhoutte Score tertinggi per regional adalah :

- Jawa-Bali (2 klaster)
    - C1 (t: NTT, NTB, DIY, Bali, Banten
    - C2 : Jateng, Jatim, Jakarta-Tangerang, Jabar
    - Silhouette Score : 0.573
- Kalimantan-Sulawesi (2 klaster)
    - C1 : Tarakan, Sulbar, Malut, Maluku, Gorontalo, Sultang, Sulteng, Kalteng, Sulut, Kalbar, Kalsel
    - C2 : Kaltim-Kaltara, Sulsel
    - Silhouette Score : 0.625
- Sumatera (3 klaster)
    - C1 : Aceh, Sumbar, Riau, Lampung, Sumsel
    - C2 : Kepri, Bengkulu, Babel, Batam, Jambi
    - C3 : Sumut
    - Silhouette Score : 0.512

Secara keseluruhan, penelitian ini menegaskan bahwa algoritma Mini Batch K-means dapat digunakan secara efektif untuk pengelompokkan data distribusi listrik dengan hasil yang memuaskan dalam pemisahan klaster yang berbeda-beda Dari penelitian ini, K-Means menjadi salah satu model clustering pilihan yang akan kami bandingkan dengan model clustering lain, karena K-Means merupakan model clustering yang mudah untuk diinterpretasi dan hasil pengelompokannya juga terukur. Tidak hanya penelitian paper ini, tetapi juga penelitian lainnya juga rata-rata ada menggunakan K-Means sebagai salah satu model penelitiannya.

- **Paper 3 (Identifikasi Tingkat Pemakaian Obat Menggunakan Metode Fuzzy C-Means)**

  Penelitian ini memiliki tujuan dalam mengelompokkan tingkat pemakaian obat di Puskesmas agar pendistribusian ketersediaan obat menjadi lebih tepat dan efisien. Data yang mereka gunakan bersumber dari LPLPO Farmasi pada bulan Oktober 2020-Februari 2021 dan dilakukan proses analisis menggunakan RapidMiner. Mereka melakukan seleksi fitur, yang berakhir data yang akan mereka gunakan adalah Nama Obat, Stok Awal, Penerimaan, Persediaan, Sisa Stok. Setelah itu dilakukan data preprocessing yang dimana pengecekan data kosong, penghapusan data kosong, normalisasi dengan min-max, setelah itu dilakukan pembangunan

model Fuzzy C-Means. Parameter yang mereka gunakan adalah jumlah klaster 3, bobot 2, maksimum iterasi 25, error terkecil 10^{-5}, nilai fungsi objektif awal (P0=0).

Dari hasil analisis berdasarkan jumlah pemakaian didapat :

- Cluster 1 (rendah) : 179 jenis obat
- Cluster 2 (sedang) : 18 jenis obat
- Cluster 3 (tinggi) : 4 jenis obat

Hasil ini diharapkan dapat menjadi acuan dalam perencanaan dan pengendalian obat di puskesmas.

Walaupun penelitian ini berbeda jauh dengan penelitian kami yang dimana penelitian mereka melakukan analisis tingkat pemakaian obat yang berbeda dengan penelitian kami tentang konsumsi listrik. Namun, Fuzzy C-Means bisa menjadi bahan model pertimbangan untuk menjadi salah satu model yang bisa digunakan untuk dibandingkan, dikarenakan Fuzzy C-Means dapat memberikan derajat keanggotaan tiap klaster, sehingga memungkinkan model ini dapat analisis secara fleksibel terhadap wilayah dengan pola konsumsi campuran.

- **Paper 4 (Penggunaan X-Means Clustering Method untuk Mengelompokkan Potensi Sekolah Menengah Unggul di Kabupaten Banyumas)**

  Penelitian ini memiliki tujuan dalam mengelompokkan sekolah-sekolah menengah (SMA dan SMK) di Kabupaten Banyumas berdasarkan potensi dan fasilitas agar dapat memudahkan pemerintah dalam melakukan pengembangan maupun revitalisasi secara merata. Data yang mereka dapatkan ini dari pangkalan data kemendikbud yang terkumpul 118 data sekolah se-kabupaten Banyumas. Mereka pertama-tama melakukan observasi dengan terjun ke lapangannya langsung, lalu merancang rumusan masalah, studi pustaka, tujuan, hingga pertanyaan interview. Setelah itu, mereka melakukan interview dan pengumpulan data, setelah itu dilakukan analisis data. Dari analisis data didapat hasil :

  - Cluster 1 (baik) : 26 sekolah
  - Cluster 2 (unggul) : 28 sekolah
  - Cluster 3 (kurang) : 21 sekolah
  - Cluster 4 (cukup) : 43 sekolah

  Lalu klaster tersebut dilakukan evaluasi menggunakan Davis-Bouldin Index (DBI) = 0.846 yang menunjukkan klaster tersebut cukup ideal dalam mengelompokkan sekolah berdasarkan tujuh kriteria, yaitu Peserta Didik, Rombel, Guru, Pegawai, R. Kelas, R. Lab, R. Perpus.

  Alasan dari kami menggunakan model X-Means ini adalah, berdasarkan analisis mereka walaupun secara manual, mereka tidak menentukan terlebih dahulu jumlah cluster yang ingin mereka masukkan kelompoknya. Sehingga pada implementasi secara komputasi, X-Means juga tidak menentukan jumlah kluster

dan X-Means merupakan hasil penyempurnaan dari K-Means dan kluster X-Means itu jauh lebih realistis.

- **Paper 5 (Pengelompokan Data Pendistribusian Listrik Menggunakan Algoritma Density Based Spatial Clustering of Application With Noise (DBSCAN))**

  Penelitian ini melakukan analisis pengelompokkan data pendistribusian listrik dengan metode clustering yang bertujuan untuk membantu dalam efisiensi distribusi konsumsi listrik. Data didapat dari referensi literatur, observasi pada website PT. PLN (Persero), terdapat 7 kolom data, yaitu satuan PLN/provinsi, jalan umum, industri, bisnis, gedung kantor pemerintah, sosial, dan rumah tangga. Setelah itu dilakukan tahap preprocessing yang dimana dikelompokkan menjadi regional, yaitu Sumatera, Jawa-Bali, Kalimantan-Sulawesi, dan Papua. Proses clustering tidak dilakukan untuk regional Papua karena jumlah wilayah yang terbatas dan tidak memungkinkan membentuk cluster. Kemudian, menentukan nilai parameter epsilon dan min sample menggunakan GridSearchCV, lalu membangun model DBSCAN dan terakhir melakukan evaluasi menggunakan Silhouette Score. Hasil yang didapat dari analisis yang telah dilakukan adalah :
  - Jawa-Bali
    - Eps : 1.7
    - Min sample : 4
    - Silhouette Score : 0.62
    - Jumlah Cluster : 2
  - Kalimantan-Sulawesi
    - Eps : 1.4
    - Min sample : 3
    - Silhouette Score : 0.67
    - Jumlah Cluster : 2
  - Sumatera
    - Eps : 1.9
    - Min sample : 3
    - Silhouette Score : 0.64
    - Jumlah Cluster : 2

  Penelitian ini juga ada melakukan perbandingan dengan metode lain, yaitu K-means dan mean shift. Yang didapat bahwa K-Means ternyata jauh lebih optimal dalam melakukan pengelompokkan untuk kasus ini. Namun, tetap algoritma DBSCAN menjadi pilihan yang baik karena mampu menangani noise dalam data dan mengolahnya menjadi 2 hingga 3 cluster berdasarkan letak geografis.

Alasan kami memilih DBSCAN sebagai salah satu model adalah karena DBSCAN cocok dalam melakukan pengelompokkan distribusi yang tidak beraturan, selain itu DBSCAN juga bisa mengabaikan atau memisahkan wilayah-wilayah yang ekstrem (Outlier) yang dimana hal itu diharapkan cocok untuk bisa melakukan distribusi konsumsi listrik

C. Purpose & benefit

- ***Tujuan***
  - **Menganalisis pola konsumsi listrik**
    Dengan menganalisis pola konsumsi listrik, bisa membantu dalam mengidentifikasi kawasan-kawasan di Indonesia yang menggunakan pemakaian listrik yang berlebih
  - **Menerapkan metode clustering**
    Untuk menganalisis sebuah pola konsumsi listrik, maka perlu diketahui pengelompokkannya dengan menggunakan metode clustering
  - **Membantu perencanaan distribusi listrik**
    Dengan menganalisis pola konsumsi listrik, diharapkan data yang diperoleh dari hasil analisis dengan k-means ini bisa menjadi sebuah data yang membantu agar distribusi listrik tersebar secara merata dengan disesuaikan kebutuhan yang secukupnya
- ***Manfaat***
  - **Efisiensi Distribusi Listrik**
    Dengan memahami pola konsumsi listrik di setiap provinsi setelah melakukan analisis dan menghasilkan suatu visualisasi, maka akan memudahkan dalam pendistribusian listrik menjadi lebih tersebar secara efisien
  - **Optimasi Pengguna Sumber Daya**
    Pemerintah dan penyedia listrik dapat mengoptimasikan penggunaan sumber daya secara merata agar dapat secar aefektif mempertimbangkan kelompok provinsi yang memiliki kebutuhan listrik serupa
  - **Menyediakan Rekomendasi Kebijakan Berbasis Data**
    Pemerintah dapat menggunakan hasil analisis yang telah dibuat oleh kami sebagai sarana dalam merancang kebijakan energi yang lebih berbasis data

D. Methods

- ***Dataset***
  Dataset yang kami gunakan bersumber dari Statistik PLN dan BPS pada tahun 2021-2023. Terdapat dataset konsumsi (Residential, Industrial, Business, Social, Gov. Office, Publ. Street, Total, (%) per 34 provinsi yang ada di Indonesia pada

tahun 2021-2023), dataset jumlah penduduk per provinsi pada tahun 2021-2023, dan kapasitas pembangkit per provinsi pada tahun 2021-2023

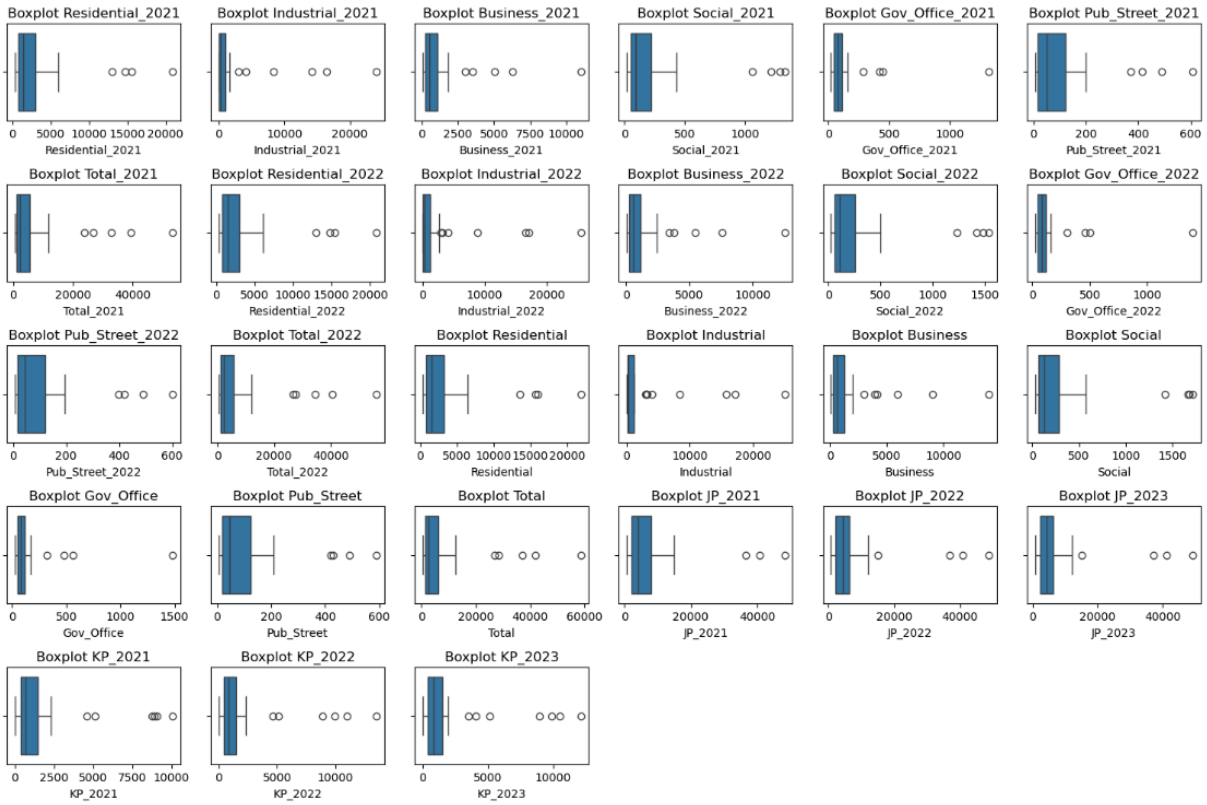
- ***Preprocess***

  Dataset konsumsi awalnya didapat dalam format PDF, sehingga perlu dikonversi dari PDF ke CSV. Setelah itu, data dibersihkan karena awal dalam bentuk unnamed seperti di bawah ini

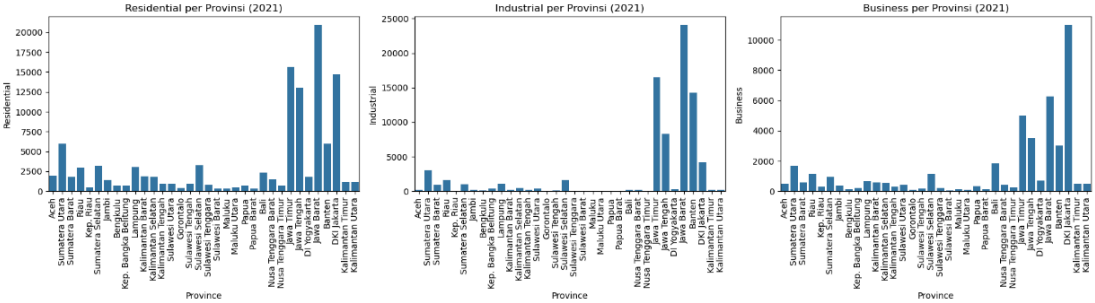
	Table Energy Sold by Type of Customers (GWh)	Unnamed: 0	Unnamed: 1	Unnamed: 2	Unnamed: 3	2021	Unnamed: 6	Unnamed: 7	Unnamed: 8
0	PLN Operational Unit/ Residential Industrial B...	Residential	Industrial	Business	Social	Gov. Office	Publ. Street	Total	(%)
1	Province	NaN	NaN	NaN	NaN	Building	Lighting	NaN	NaN
2	UIW Aceh	1,929.59	190.56	515.04	208.23	107.18	123.87	3,074.47	1.19
3	UIW North Sumatera	5,998.75	3,082.97	1,672.31	432.68	146.38	415.31	11,748.40	4.56
4	UIW West Sumatera	1,781.19	945.24	573.7	169.92	80.45	95.7	3,646.20	1.42

  Ubah menjadi sebuah kolom. Setelah itu dari provinsi yang masih dalam bentuk bahasa Inggris diubah menjadi bahasa Indonesia dengan melakukan replace pada kolom provinsi. Setelah itu ditampung ke csv baru. Setelah itu melakukan preprocessing kembali untuk mengubah angka yang ada koma menjadi tidak ada koma. Lalu, di dataset utama Kalimantann Timur dan Kalimantan Utara digabung, sehingga kami memisahnya menjadi dua. Lalu untuk dataset Jumlah Penduduk hapus row paling atas, lalu ubah ke numerik, dan hapus missing value. Begitupun juga dengan dataset Kapasitas Pembangkit, hapus row paling atas, lalu ubah ke numerik, dan hapus missing value, dan mengubah nama provinsi. Setelah itu semua dataset digabung dan dilakukan normalisasi menggunakan RobustScaler dikarenakan banyak data-data yang nilainya ekstrem, kemudian outlier yang sangat banyak.

- ***EDA***

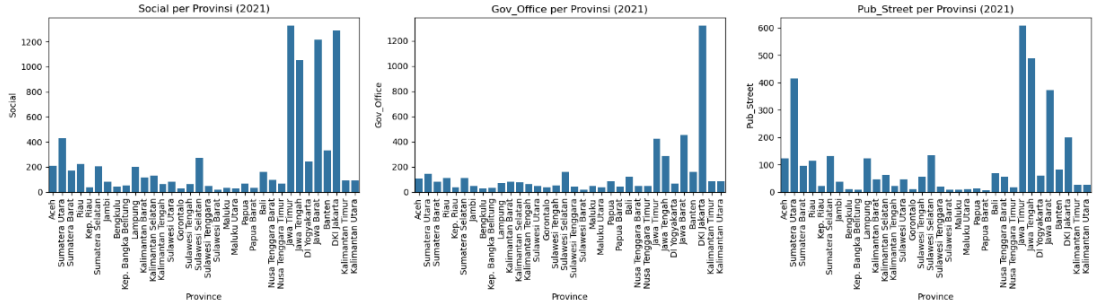


Berdasarkan boxplot di atas, pendistribusian konsumsi listrik masih tidak merata, karena di setiap boxplot memiliki outlier yang sangat tinggi yang menunjukkan pembagiannya tidak merata. Kemudian, setiap tahunnya terlihat outlier dan pola distribusinya tidak terlalu berubah yang dimana menunjukkan tren konsumsi masih stabil walaupun adanya ketimpangan antar provinsi.


Residential per Provinsi (2021)
Residential
Province

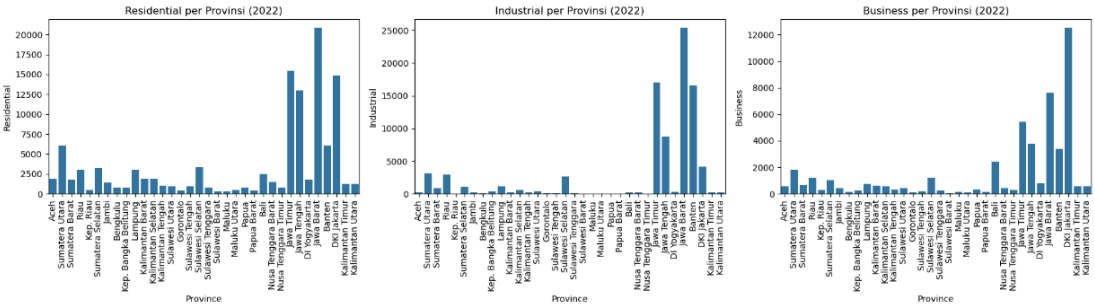
Industrial per Provinsi (2021)
Industrial
Province

Business per Provinsi (2021)
Business
Province


Social per Provinsi (2021)
Social
Province

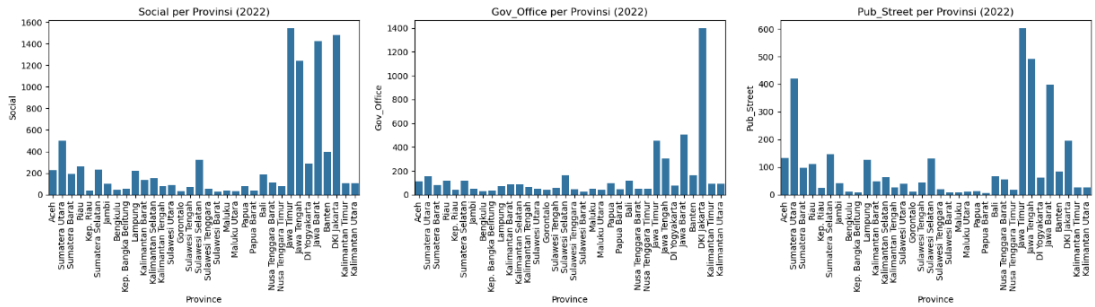
Gov_Office per Provinsi (2021)
Gov_Office
Province

Pub_Street per Provinsi (2021)
Pub_Street
Province


Residential per Provinsi (2022)
Residential
Province

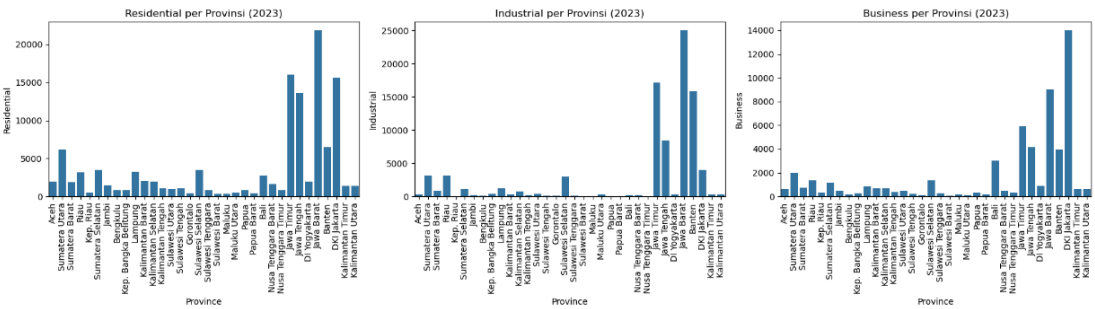
Industrial per Provinsi (2022)
Industrial
Province

Business per Provinsi (2022)
Business
Province


Social per Provinsi (2022)
Social
Province

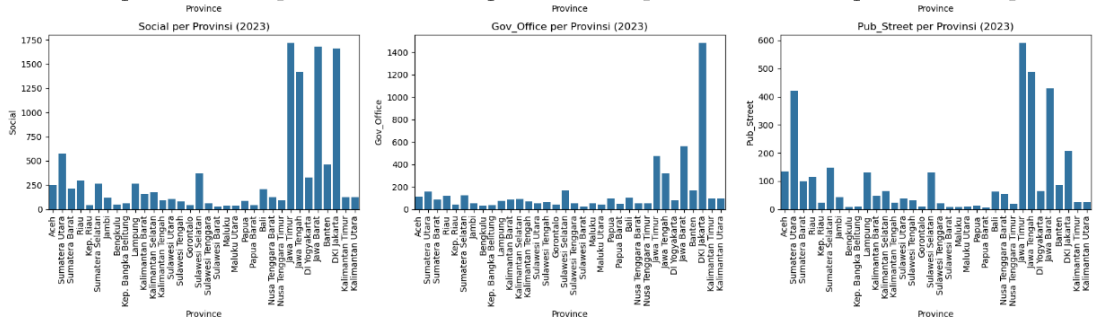
Gov_Office per Provinsi (2022)
Gov_Office
Province

Pub_Street per Provinsi (2022)
Pub_Street
Province


Residential per Provinsi (2023)
Residential
Province

Industrial per Provinsi (2023)
Industrial
Province

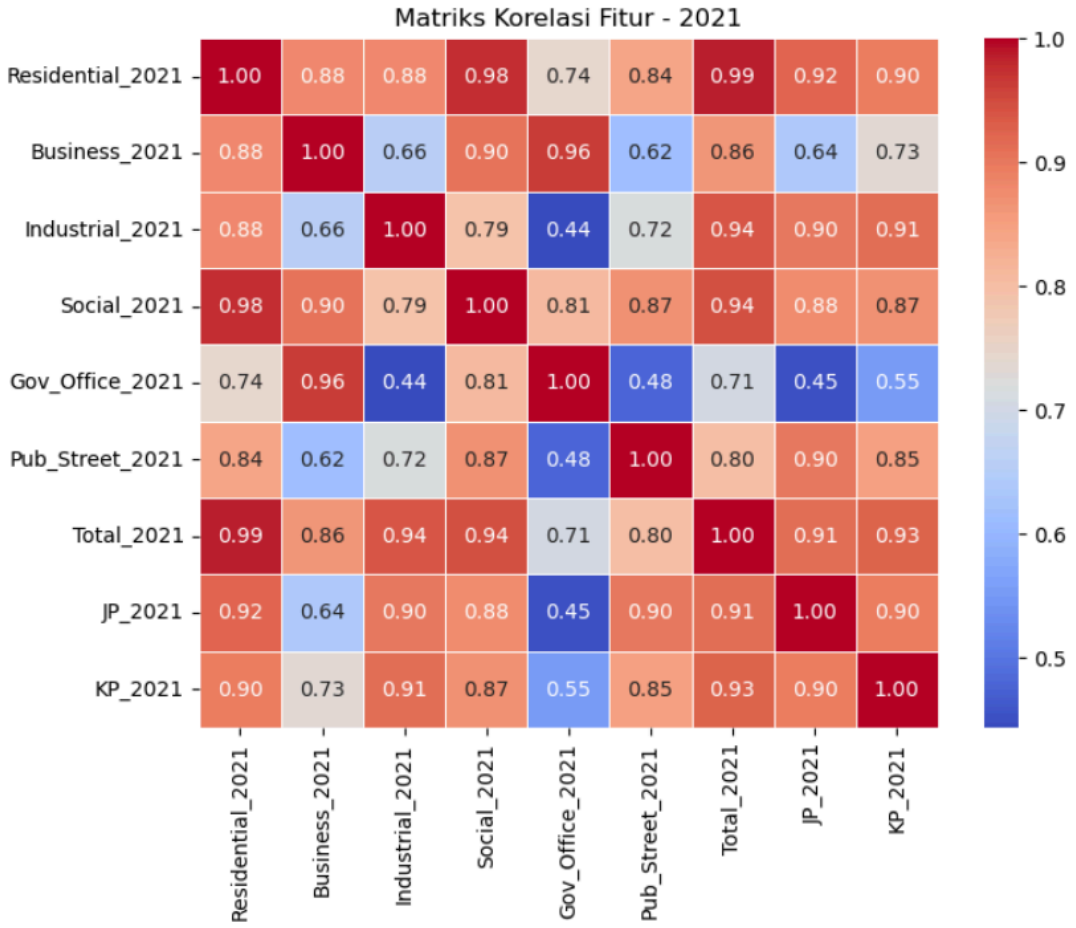
Business per Provinsi (2023)
Business
Province

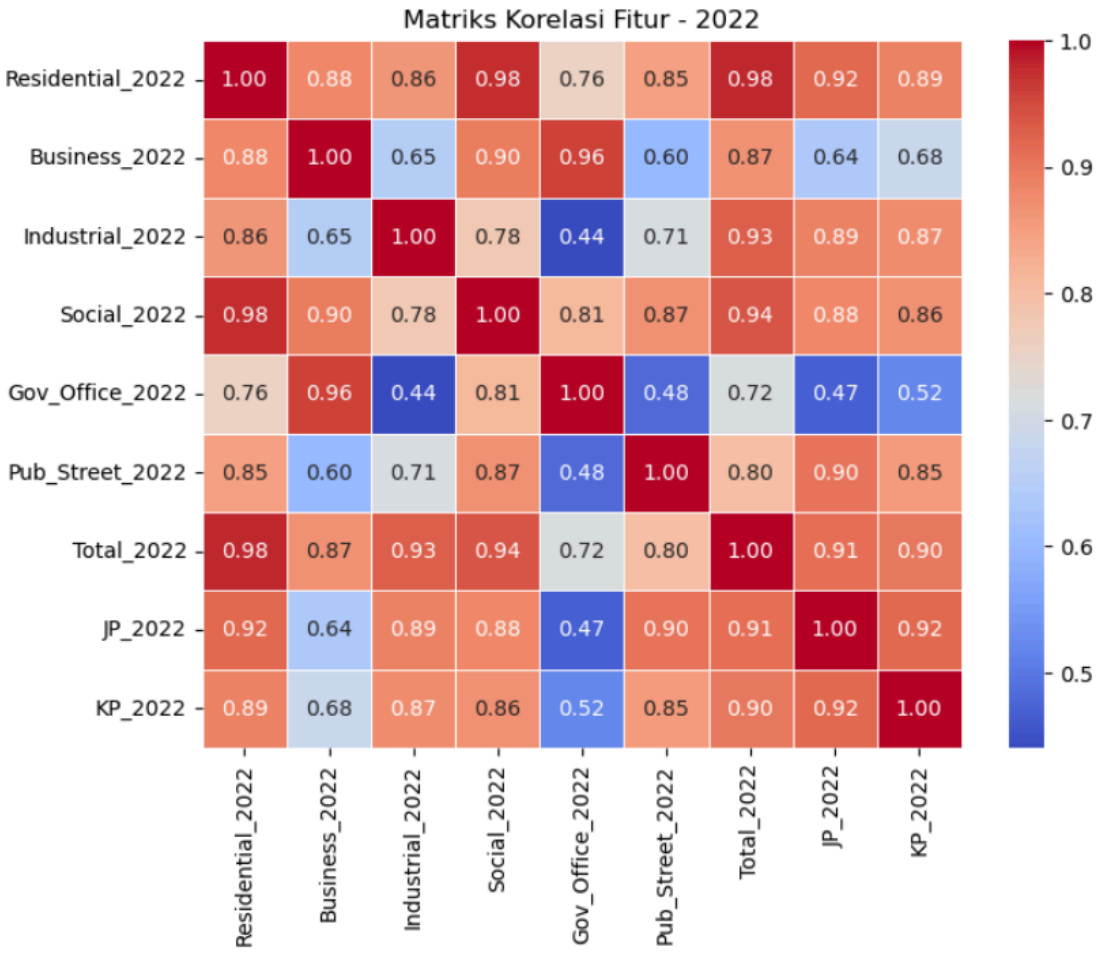

Social per Provinsi (2023)
Social
Province

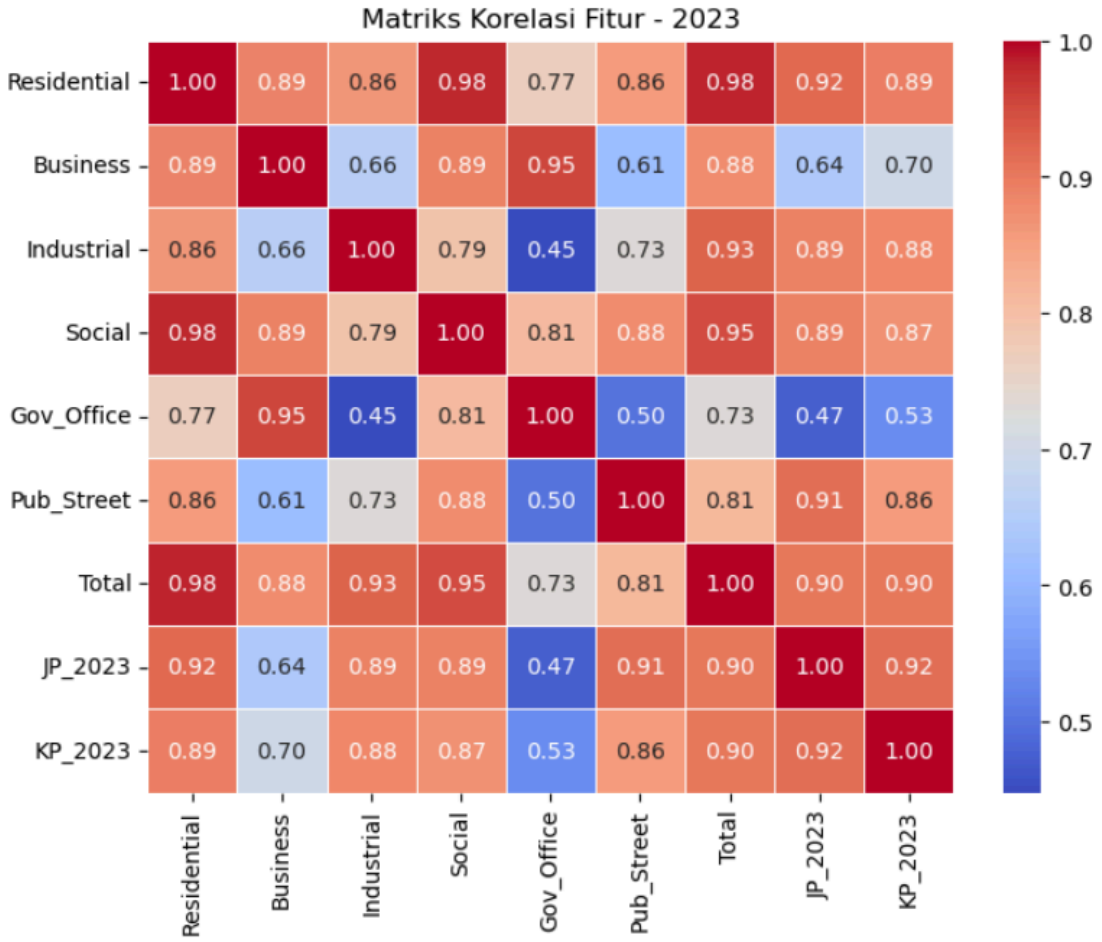
Gov_Office per Provinsi (2023)
Gov_Office
Province

Pub_Street per Provinsi (2023)
Pub_Street
Province

Berdasarkan gambar di atas, terlihat bahwa ketimpangan dalam pendistribusian konsumsi listrik di Indonesia pada tahun 2021-2023, karena di daerah-daerah Jawa seperti Jawa Barat, DKI Jakarta, Jawa Timur, dsb menggunakan jumlah konsumsi listrik yang sangat berlebih sedangkan yang lain penggunaan konsumsi listriknya sangat rendah. Tidak hanya dari satu sektor namun terhadap semua sektor.




Matriks Korelasi Fitur - 2022
Residential_2022 1.00 0.88 0.86 0.98 0.76 0.85 0.98 0.92 0.89
Business_2022 0.88 1.00 0.65 0.90 0.96 0.60 0.87 0.64 0.68
Industrial_2022 0.86 0.65 1.00 0.78 0.44 0.71 0.93 0.89 0.87
Social_2022 0.98 0.90 0.78 1.00 0.81 0.87 0.94 0.88 0.86
Gov_Office_2022 0.76 0.96 0.44 0.81 1.00 0.48 0.72 0.47 0.52
Pub_Street_2022 0.85 0.60 0.71 0.87 0.48 1.00 0.80 0.90 0.85
Total_2022 0.98 0.87 0.93 0.94 0.72 0.80 1.00 0.91 0.90
JP_2022 0.92 0.64 0.89 0.88 0.47 0.90 0.91 1.00 0.92
KP_2022 0.89 0.68 0.87 0.86 0.52 0.85 0.90 0.92 1.00
Residential_2022
Business_2022
Industrial_2022
Social_2022
Gov_Office_2022
Pub_Street_2022
Total_2022
JP_2022
KP_2022
1.0
0.9
0.8
0.7
0.6
0.5



Berdasarkan gambar matrix correlation di atas (2021-2023), tidak ada yang kurang dari 0 hubungannya, yang menunjukkan hampir semua fitur saling berkaitan satu sama lain walaupun sedikit. Hubungan antara fitur Total dengan fitur lainnya sangat tinggi, secara logika Total memiliki hubungan agregasi terhadap masing-masing jumlah sektor. Jumlah Penduduk dan Kapasitas Pembangkit memiliki hubungan yang sangat tinggi, yang memungkinkan keduanya ini memiliki hubungan yang dimana kapasitas pembangkit bergantung pada jumlah penduduk. Kemudian Residential dan Social juga memiliki hubungan yang sangat erat yang memungkinkan area permukiman dan fasilitas sosial berkembang seiringan.

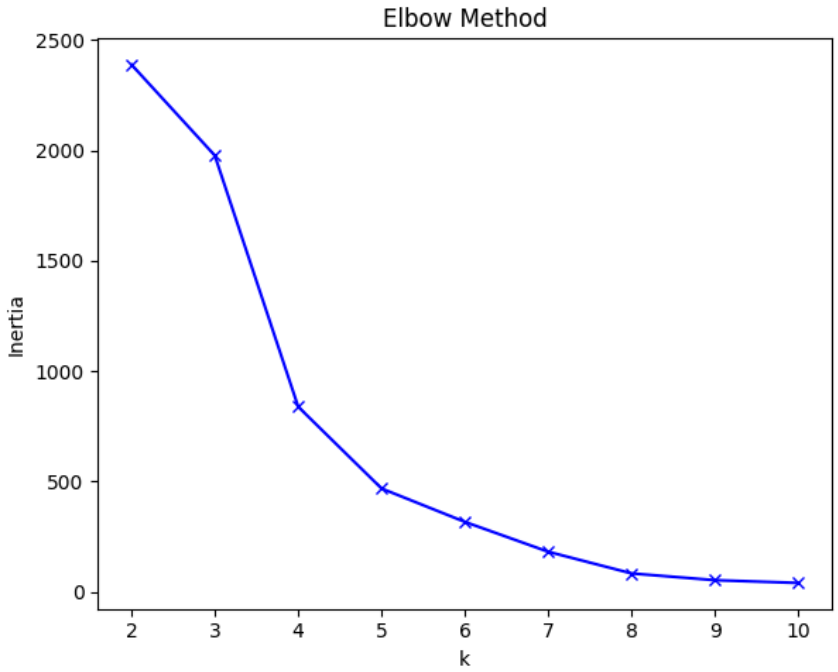
- ***Model***

  Model yang kami gunakan ada 5 berdasarkan literatur yang kami dapatkan, yaitu :

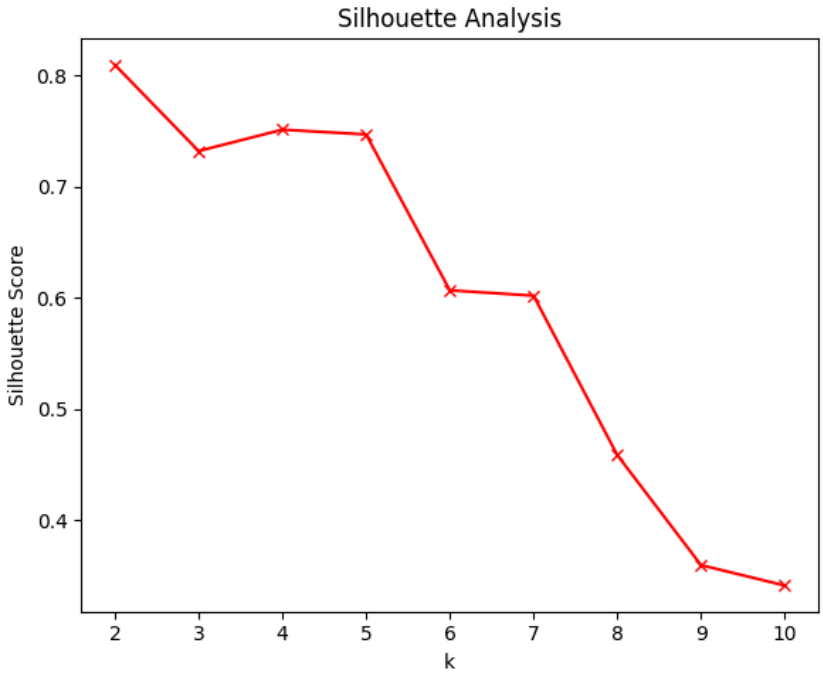
  - K-Means
  - K-Medoids
  - Fuzzy C-Means
  - X-Means
  - DBSCAN

E. Experiment

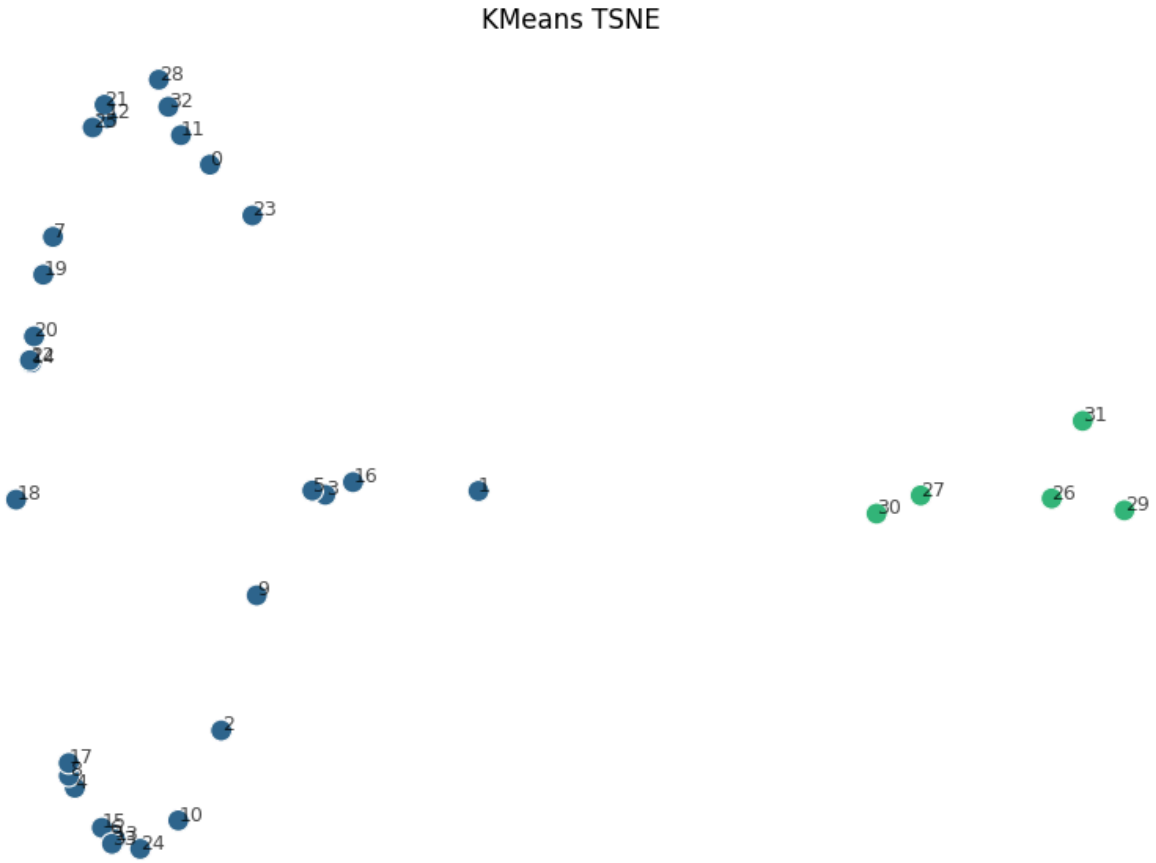
KMEANS



Diatas merupakan hasil grafik Elbow Method menggunakan KMeans menunjukan perubahan jumlah jarak kuadrat antara titik data dengan pusat cluster terhadap jumlah clusternya. Dilihat bahwa penurunan inertia yang tajam akan diikuti dengan penurunan yang lebih datar menunjukan jumlah cluster yang optimal yang ditunjukkan terjadi pada k = 2 selanjutnya penurunan inertia mulai datar dan menjadi lebih sedikit yang menunjukan kalau menambah lebih banyak cluster tidak akan menghasilkan pengurangan signifikan terhadap inertia. K = 2 merupakan hasil yang paling optimal berarti dua cluster saja sudah cukup untuk menggambarkan struktur data yang ada ditambah lagi penambahan cluster lebih banyak lagi tidak akan memberikan perubahan yang signifikan.

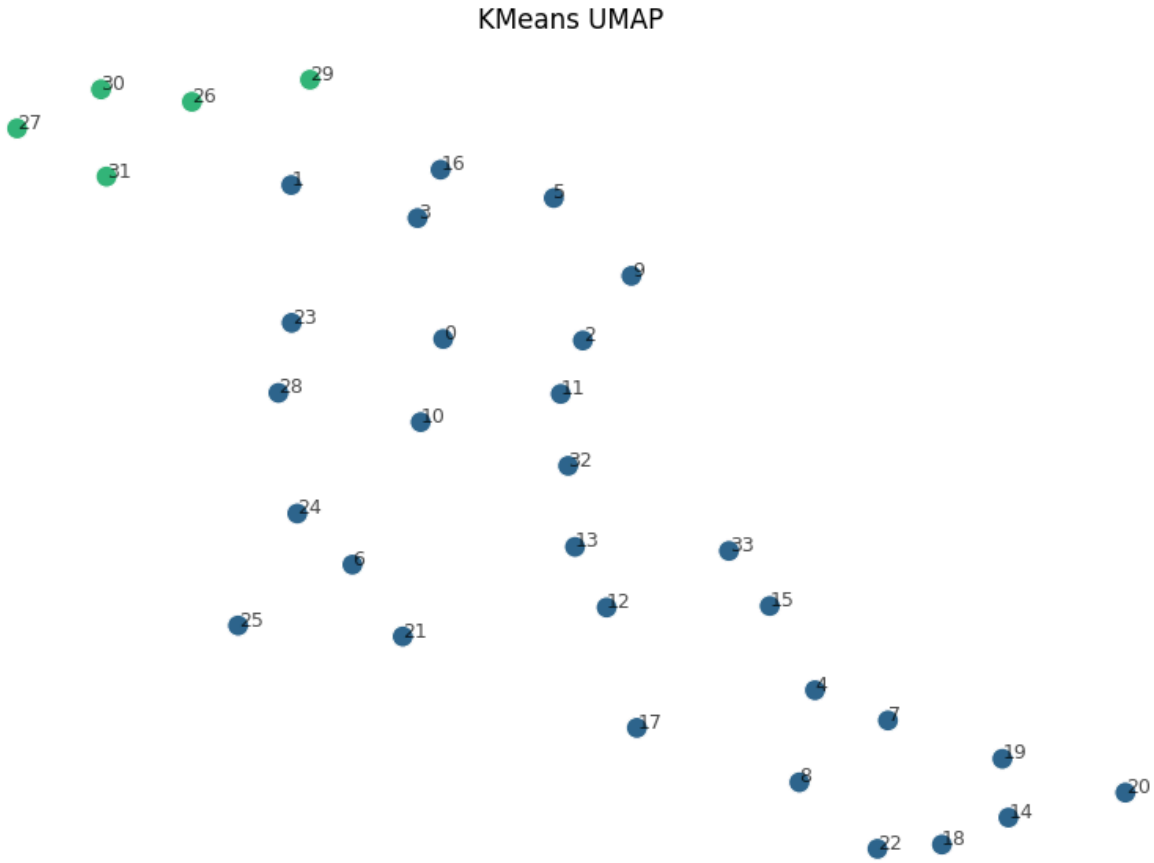


Grafik diatas untuk mengukur silhouette score terbaik pada setiap titik data yang cocok dengan clusternya. Semakin tinggi nilai silhouette scorenya atau semakin mendekati 1 maka akan menunjukan bahwa titik data cluster tersebut berada di posisi yang baik dalam clusternya. Dapat dilihat dari grafik bahwa k = 2 menunjukan nilai silhouette score terbaik dengan score 0.8099 dan mengindikasikan bahwa cluster yang terbentuk cukup jelas. Sedangkan setelah k = 2 mengalami penurunan ini akan memberitahu bahwa ketika menambahkan cluster lebih banyak lagi tidak akan merubah hasil clustering KMeans menjadi lebih baik kualitasnya, yang artinya dua cluster sudah sangat optimal dan efisien dalam pengelompokan data serta mendukung juga untuk hasil dari grafik Elbow method sebelumnya.



Graf diatas merupakan t-distributed Stochastic Neighbor Embedding yang dihasilkan dari model KMeans yang berguna untuk pemberian gambaran visual mengenai bagaimana terkelompoknya setiap provinsi yang ada di Indonesia berdasarkan pola konsumsi listrik dengan melakukan pengurangan dimensi yang digunakan dalam mereduksi data berdimensi tinggi supaya bisa divisualisasikan dengan tujuan memetakan titik data yang mirip dalam ruang dimensi ke titik yang berdekatan.

Dapat dilihat dari graf tersebut terdapat distribusi cluster yang terpisah secara jelas yaitu satu kelompok berwarna biru dan kelompok lainnya berwarna hijau, ini menandakan bahwa model KMeans telah tepat mengelompok cluster menjadi k = 2. Serta dari visualisasi persebarannya kelompok biru menunjukan kecenderungan data lebih tersebar secara merata tetapi masih adanya konsentrasi pada area tertentu. Hal ini mencerminkan provinsi dengan tingkat konsumsi yang lebih rendah dan lebih tersebar secara geografis sedangkan kelompok hijau menunjukan lebih terpusat dan padat pada bagian tertentu yang menandakan bahwa provinsi yang ada di kelompok ini provinsi yang lebih berkembang dan maju karena memiliki pola konsumsi listrik yang serupa.



Grafik diatas merupakan Uniform Manifold Approximation and Projection yang digunakan untuk mereduksi dimensi data dan memberikan gambaran visual tentang bagaimana provinsi yang ada di Indonesia terkelompok berdasarkan pola konsumsi listrik yang telah diterapkan menggunakan model KMeans dengan mengubah data berdimensi tinggi menjadi dua dimensi representasi agar mudah divisualisasikan.

Berdasarkan hasil grafik diatas dapat terlihat adanya pemisahan cluster yaitu cluster hijau dengan titik-titik yang berada di bagian atas grafik dan terkelompok dengan jelas ini akan menunjukan bahwa provinsi-provinsi yang ada id cluster ini memiliki konsumsi listrik yang lebih tinggi yang akan mencakup hasil dari daerah yang berkembang dan maju karena tentunya akan membutuhkan pemakaian listrik yang lebih banyak. Sedangkan kelompok biru titik-titiknya tersebar lebih merata di bagian bawah grafik ini akan mencerminkan provinsi-provinsi dengan konsumsi listrik yang lebih rendah yang cenderung kurang berkembang daerahnya. UMAP, dengan kemampuan untuk menjaga struktur global data, memperlihatkan lebih jelas hubungan antara klaster, terutama memperlihatkan provinsi yang lebih berkembang (kelompok hijau) dan bagaimana mereka terpisah dari provinsi yang lebih rendah konsumsi listriknya (kelompok biru).

KMeans dipilih karena dapat bekerja dengan baik saat data memiliki cluster yang berbentuk data dalam satu cluster harus memiliki kedekatan yang tinggi antara satu sama lain yang bisa mencerminkan konsumsi listrik yang mirip di setiap provinsi dalam cluster itu serta KMeans itu memiliki kesederahan dan kemampuan untuk mengelompokan data kedalam cluster berdasarkan kedekatan centroidnya. Artinya dapat diasumsikan bahwa setiap provinsi dengan karakteristik konsumsi listrik yang serupa akan digolongkan kedalam suatu cluster yang jelas. Berikut adalah hasil dari clustering KMeans :

Provinsi dalam cluster 0:

Aceh, Sumatera Utara, Sumatera Barat, Riau, Kep. Riau, Sumatera Selatan, Jambi, Bengkulu, Kep. Bangka Belitung, Lampung, Kalimantan Barat, Kalimantan Selatan, Kalimantan Tengah, Sulawesi Utara, Gorontalo, Sulawesi Tengah, Sulawesi Selatan, Sulawesi Tenggara, Sulawesi Barat, Maluku, Maluku Utara, Papua, Papua Barat, Bali, Nusa Tenggara Barat, Nusa Tenggara Timur, DI Yogyakarta, Kalimantan Timur, Kalimantan Utara.

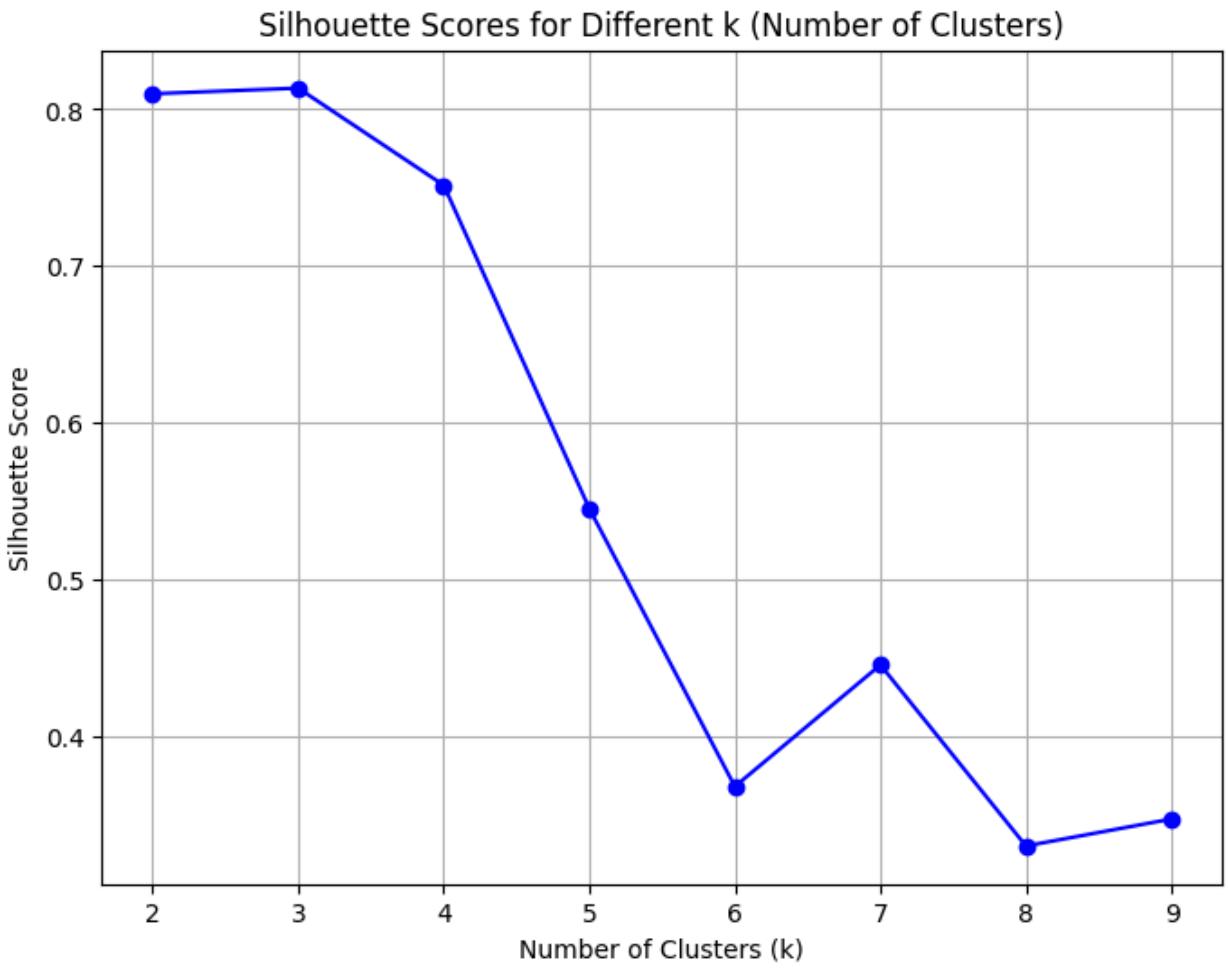
Karakteristik cluster ini adalah konsumsi listrik yang renda dengan sebagian besar provinsi memiliki tingkat urbanisasi yang lebih rendah dan sektor industri yang tidak sebesar provinsi yang ada di daerah pulau Jawa.

Provinsi dalam cluster 1:

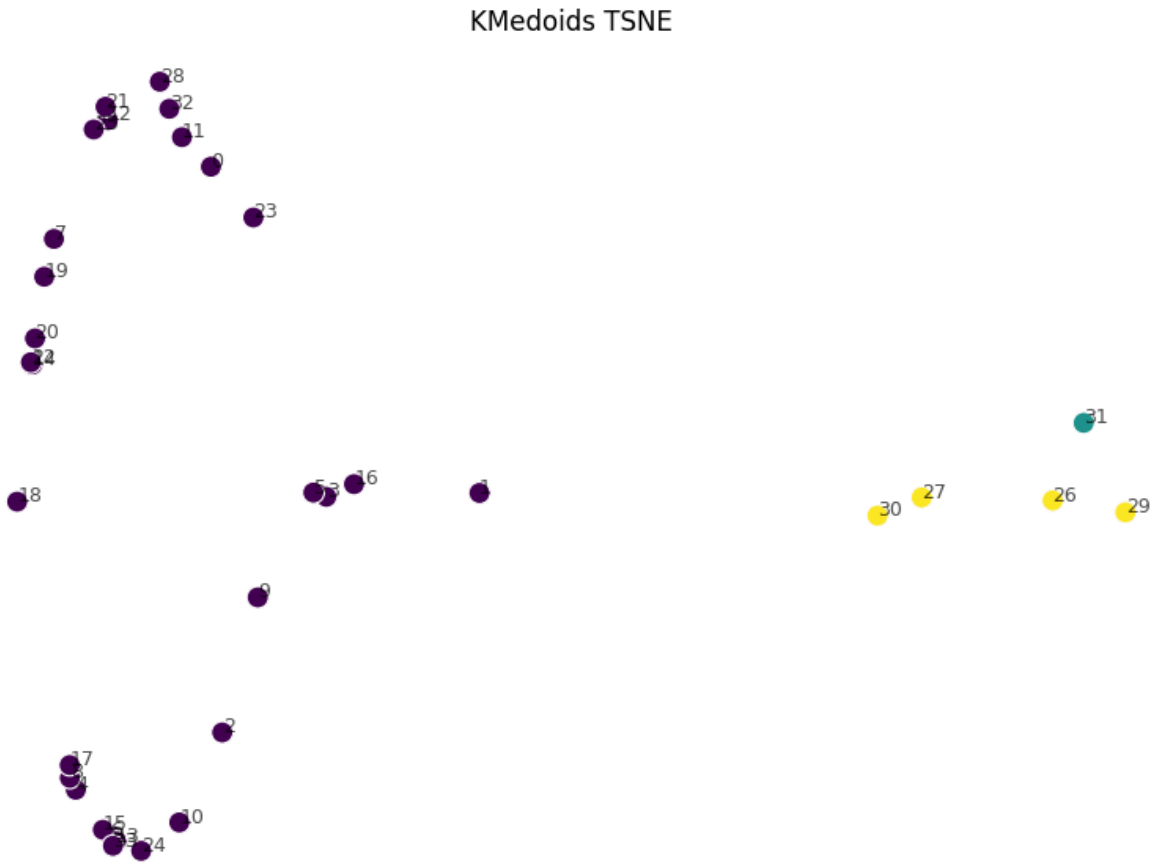
Jawa Timur, Jawa Tengah, Jawa Barat, Banten, DKI Jakarta.

Karakteristik cluster ini memiliki konsumsi listrik yang tinggi dengan banyak provinsinya memiliki kepadatan penduduk yang cukup tinggi dan juga memiliki banyak kawasan industri dengan provinsi-provinsi ini lebih terurbanisasi dengan tentunya permintaan listrik yang cukup tinggi.

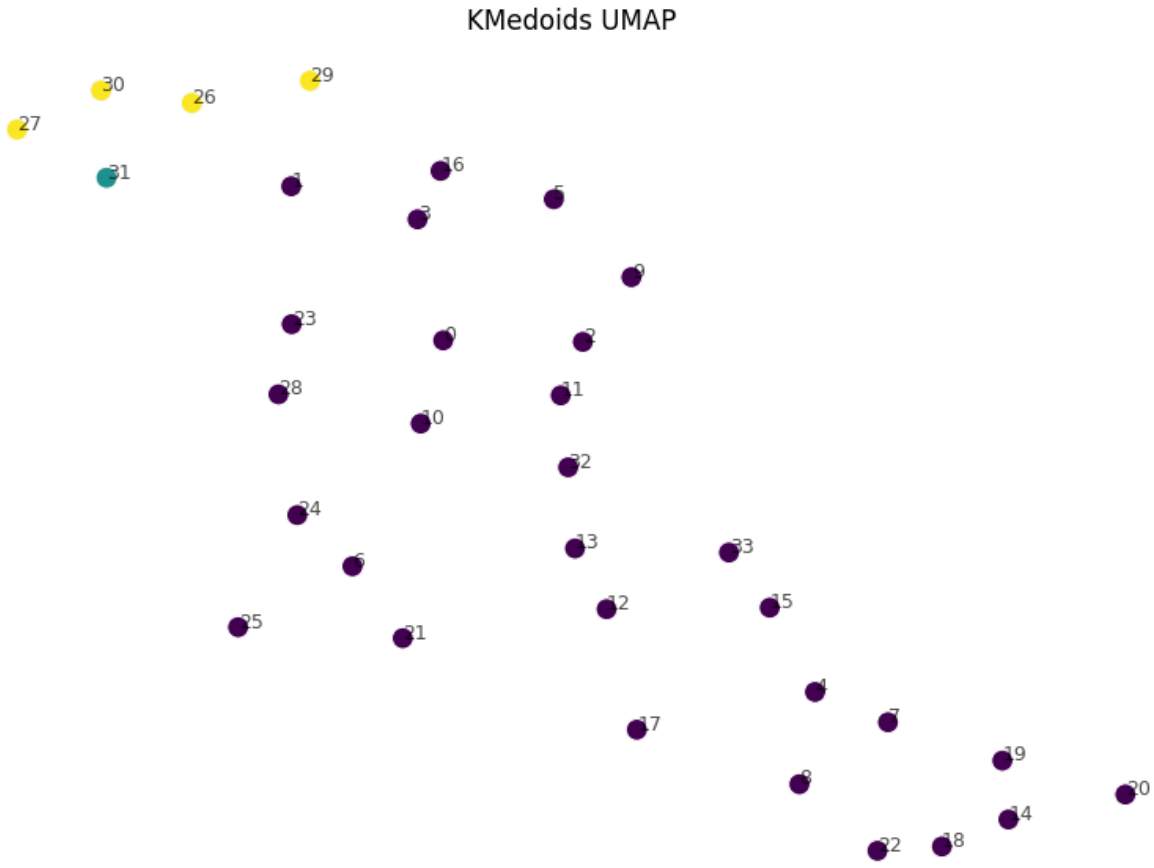
KMEDOIDS



Grafik diatas menunjukan silhouette score terbaik untuk berbagai jumlah cluster berdasarkan model KMedoids, bisa dilihat bahwa silhouette score tertinggi berada pada k = 3 dengan score 0.8134 yang menunjukan bahwa setelah cluster k = 3 ini mengalami score yang menurun dan semakin rendah jika melakukan penambahan jumlah cluster dengan itu menunjukan bahwa jumlah cluster yang lebih banyak akan mengakibatkan pemisahan cluster yang kurang baik dan memungkinkan cluster yang lebih banyak menyebabkan tumpang tindih dengan cluster lainnya.



Berdasarkan graf diatas menunjukan bahwa terdapat tiga kelompok atau cluster yang terbagi secara jelas dari model KMedoids, kelompok ungu yang berisi titik-titik dengan kecenderungan lebih tersebar secara merata tetapi masih konsentrasinya fokus pada area tertentu yang mencerminkan bahwa provinsi dengan tingkat konsumsi listrik yang lebih rendah dan lebih tersebar secara geografis, sedangkan kelompok kuning titik-titiknya lebih terpusat dan padat menunjukan bahwa provinsi dalam kelompok ini berkembang dan maju karena konsumsi listrik yang lebih tinggi dan serupa. Lalu kelompok hijau hanya berisi satu titik yang menandakan bahwa provinsi ini sangat berbeda dari yang lain padahal ketika dilihat dari kedekatannya dengan kelompok sangat memungkinkan model melakukan overfitting ataupun penentuan jumlah cluster yang kurang optimal.



Graf diatas menunjukan hasil visualisasi model KMedoids menggunakan UMAP terlihat adanya 3 kelompok juga yang terbentuk kelompok ungu dengan tersebar merata yang lebih terkonsentrasi di daerah bawah yang menunjukan provinsi dengan konsumsi yang lebih rendah dan untuk kelompok kuning lebih terpusat dan padat pada bagian atas yang mencerminkan tinggi konsumsi listrik yang ada di provinsi ini karena lebih berkembang dan maju sehingga listrik yang dipergunakan lebih banyak serta kelompok hijau dengan hanya berisi satu titik juga dan ini deteksi sebagai sebuah outlier tetapi ini sangat memungkinkan cluster yang terbentuk kurang optimal sehingga adanya overfitting dan ketika satu cluster hanya berisi satu titik tidak bagus karena tidak bisa mencerminkan karakteristik dari cluster tersebut.

K-Medoids dipilih karena penanganannya terhadap outlier dan data tidak terstruktur sesua dengan data yang kami gunakan. Sedangkan K-Means menggunakan centroid sebagai pusat cluster, K-Medoids menggunakan medoid sebagai titik data aktual dalam klaster sehingga lebih ketahanan terhadap titik data yang ekstrem. Dari t-SNE dan UMAP, kelompok hijau yang

hanya secara individual disajikan berarti bahwa titik tersebut mempunyai pola konsumsi daya menurun yang jauh berbeda namun masih dapat dikelompokkan bersama klaster kuning yang lebih terpusat. Karena hasil Silhouette Score, K = 3 dipilih yang berarti bahwa penyelesaian cluster dengan K-Medoids mempunyai pemisahan yang lebih baik dan stabilize dibanding dengan K lebih kecil atau lebih besar.

Berikut adalah hasil dari clustering KMedoids :

Cluster 1:

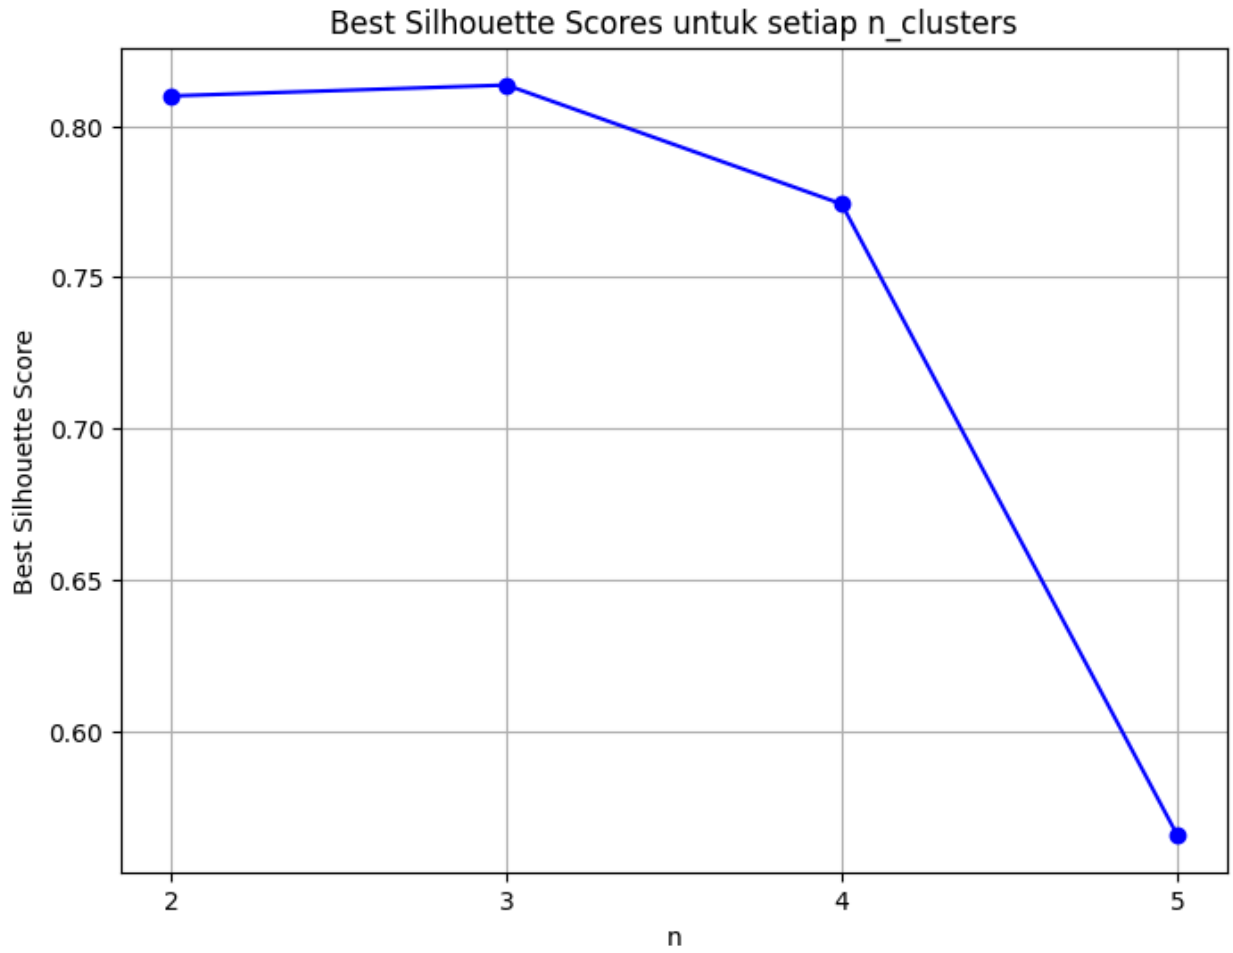
Aceh, Sumatera Utara, Sumatera Barat, Riau, Kep. Riau, Sumatera Selatan, Jambi, Bengkulu, Kep. Bangka Belitung, Lampung, Kalimantan Barat, Kalimantan Selatan, Kalimantan Tengah, Sulawesi Utara, Gorontalo, Sulawesi Tengah, Sulawesi Selatan, Sulawesi Tenggara, Sulawesi Barat, Maluku, Maluku Utara, Papua, Papua Barat, Bali, Nusa Tenggara Barat, Nusa Tenggara Timur, DI Yogyakarta, Kalimantan Timur, Kalimantan Utara

Cluster 2: DKI Jakarta

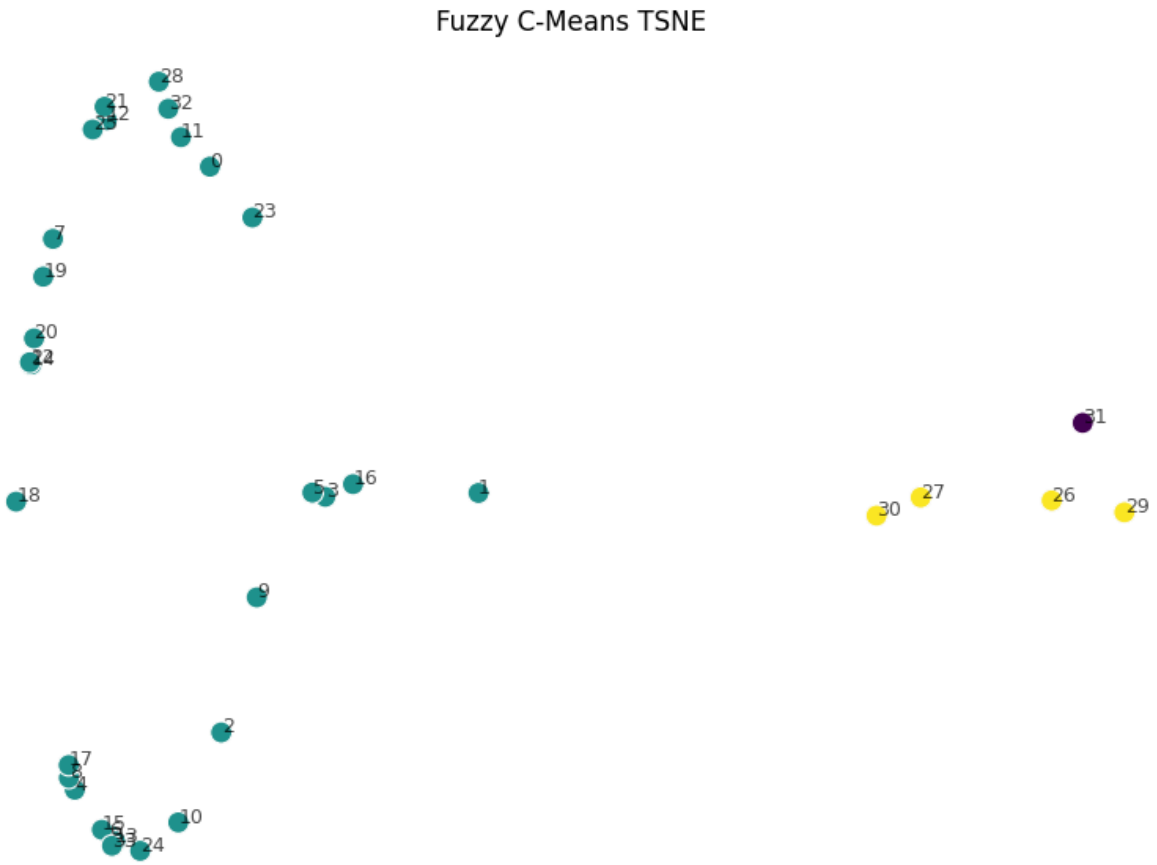
Cluster 3: Jawa Timur, Jawa Tengah, Jawa Barat, Banten

Berdasarkan hasil pengelompokan diatas akan sangat berguna untuk perencanaan distribusi energi di Indonesia, di mana kita dapat mengidentifikasi wilayah yang membutuhkan lebih banyak sumber daya listrik (kelompok kuning cluster 3) dan wilayah yang mungkin dapat mengoptimalkan penggunaan energi dengan lebih efisien (kelompok ungu cluster 1). Dengan demikian, K-Medoids membantu dalam pengelompokan provinsi berdasarkan kebutuhan energi yang nyata, serta memberikan gambaran yang lebih tepat mengenai perbedaan pola konsumsi listrik antar provinsi, tanpa terganggu oleh data outlier atau distorsi yang mungkin terjadi pada metode clustering lain tetapi masih ada masalah yaitu terjadinya kurang optimal cluster yang ditentukan ditunjukan dari kelompok hijau(cluster 2) yang hanya berisi satu provinsi saja yang tidak dapat mencerminkan karakteristik dari kelompok tersebut berarti model memaksakan pembentukan cluster meskipun ada satu provinsi yang memiliki karakteristik konsumsi listrik yang sangat berbeda yang membuat cluster tersebut terpisah padahal memiliki karakteristik dan kedekatan yang sama dengan cluster kuning dengan sangat jelas.

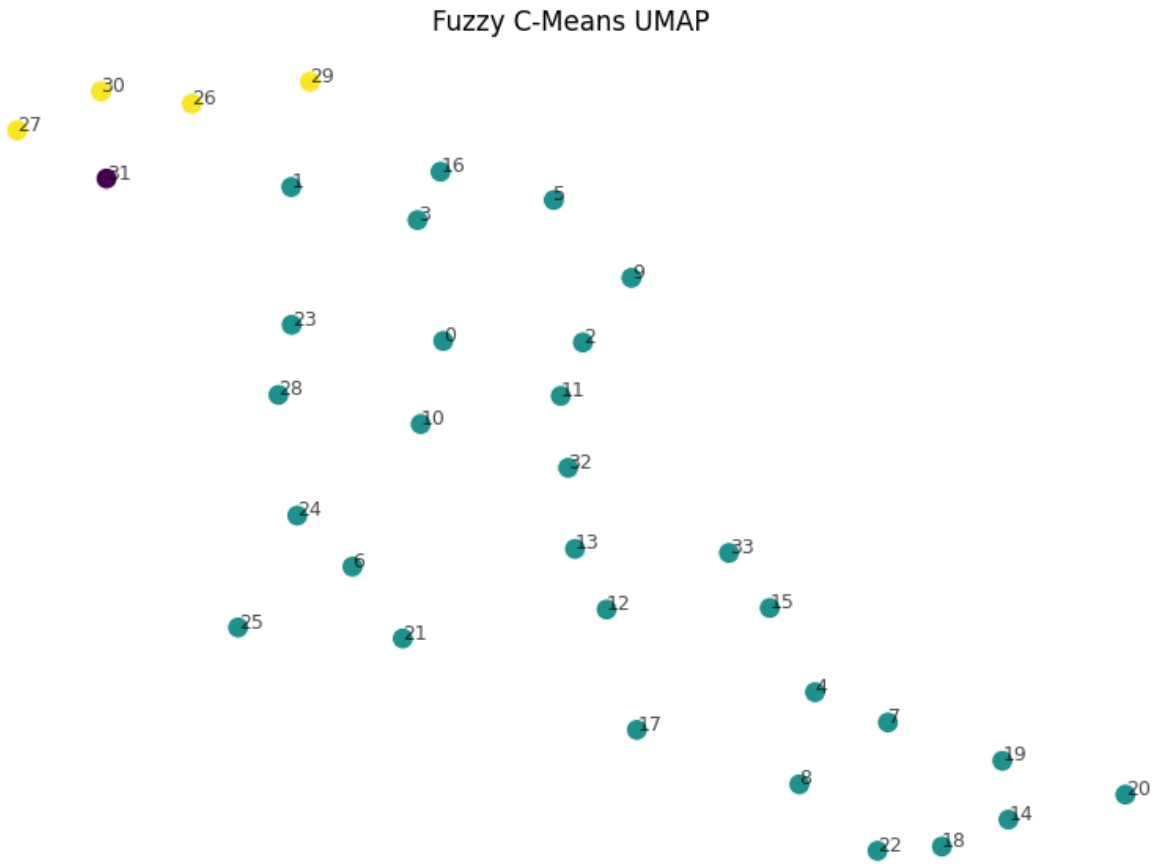
FuzzyCMeans



Grafik diatas menunjukan hasil silhouette score yang paling baik dari setiap iterasi yang dilakukan model Fuzzy C-Means, seperti yang terlihat dalam grafik, silhouette score menghasilkan hasil terbaik pada k = 3 dengan skor 0.8134, yang berarti k = 3 adalah jumlah klaster paling optimal untuk pemisahan data. Semua titik data dalam satu kluster sangat mirip satu sama lain tetapi tampak sangat berbeda dengan kluster lainnya, yang dapat dilihat dengan baik sebagai hasil yang sangat baik. Meskipun k = 2 juga menghasilkan skor yang sangat bagus sekitar 0.8099, k = 3 menawarkan banyak pemisahan yang jauh lebih jelas dan distribusi yang jauh lebih stabil antara cluster dengan k = 3 dibandingkan dengan k = 2. Sebagai tambahan, grafik juga menyoroti bahwa evaluasi setiap iterasi yang dilakukan oleh algoritma Fuzzy C-Means pada setiap jumlah cluster yang berbeda k, dan setelah k = 3 silhouette score menyusut secara tajam dengan penurunan sekitar 0.7 pada k = 4 dan lebih lanjut turun hingga 0.6 pada k = 5, yang menandakan bahwa menambah cluster setelah tiga cluster meningkatkan cakupan antar cluster dan pemisahan antar cluster yang buruk. Oleh karena itu, berdasarkan grafik ini k = 3 memberikan hasil clusteringnya yang stabil dan efisien.



Berdasarkan hasil Fuzzy C-Means yang ditunjukkan pada grafik t-SNE, terdapat tiga kelompok yang terbentuk dengan jelas. Kelompok kuning terletak di bagian kanan atas grafik dan lebih terpusat, mencerminkan provinsi dengan konsumsi listrik yang lebih tinggi yang berada di wilayah urban dan berkembang. Kelompok hijau terlihat lebih tersebar mencerminkan provinsi dengan konsumsi listrik lebih rendah dan lebih tersebar secara geografis, yang kemungkinan besar berada di wilayah pedesaan atau kurang berkembang. Kelompok ungu hanya berisi satu titik yang tidak terlalu terpisah dari cluster kuning, menunjukkan bahwa provinsi ini memiliki pola konsumsi listrik yang sama dengan cluster kuning. Tetapi malah di buat menjadi cluster tersendiri yang menunjukan adanya penentuan jumlah cluster kurang optimal dari akibat overfitting yang dilakukan model.



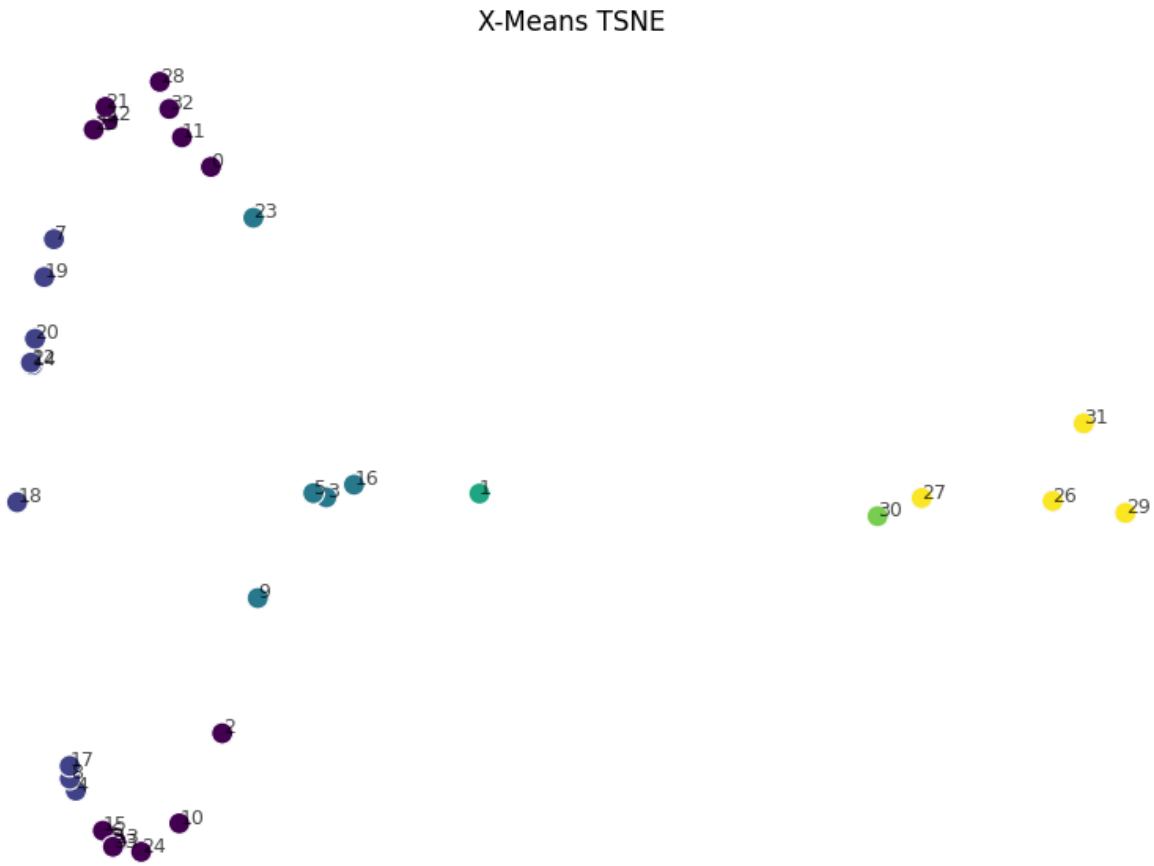
Sebagai hasil visualisasi menggunakan Fuzzy C-Means dengan visualisasi UMAP, ada tiga kelompok bisa dilihat secara jelas. Kelompok kuning terletak di bagian atas grafik dan lebih terpusat serta padat yang akan mewakili provinsi-provinsi dengan konsumsi listrik yang lebih tinggi karena provinsi-provinsi tersebut lebih berkembang dan maju dan merupakan daerah urban yang sangat padat penduduk. Di sisi lain kelompok ungu hanya berisi satu titik yang menandakan kalau dia cluster tersendiri maka adanya kemungkinan terdeteksi sebagai outlier namun karena kedekatannya dengan kelompok kuning, cluster ini kemungkinan kurang baik dan menegaskan kemungkinan overfitting model pada pengelompokan yang dilakukan model fuzzy CMeans. Kelompok ungu tersebar lebih merata di bagian bawah grafik, mewakili provinsi dengan listrik konsumsi yang lebih rendah dan yang tersebar lebih merata geografis yaitu provinsi-provinsi yang kurang berkembang dan yang kebutuhan energinya lebih rendah.

Berikut adalah hasil dari clustering Fuzzy CMeans :
Cluster 1: DKI Jakarta
Cluster 2: Aceh, Sumatera Utara, Sumatera Barat, Riau, Kep. Riau, Sumatera Selatan, Jambi, Bengkulu, Kep. Bangka Belitung, Lampung, Kalimantan Barat, Kalimantan Selatan, Kalimantan Tengah, Sulawesi Utara, Gorontalo, Sulawesi Tengah, Sulawesi Selatan, Sulawesi Tenggara,

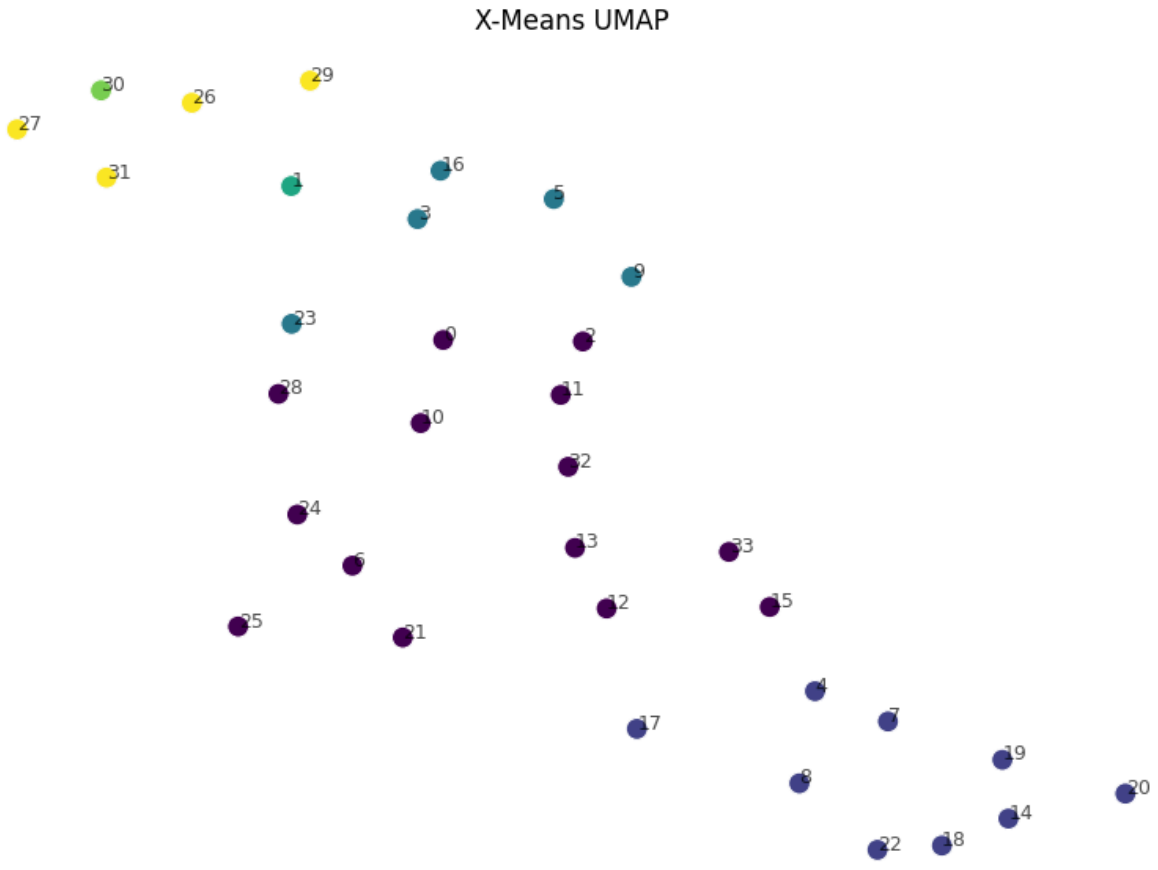
Sulawesi Barat, Maluku, Maluku Utara, Papua, Papua Barat, Bali, Nusa Tenggara Barat, Nusa Tenggara Timur, DI Yogyakarta, Kalimantan Timur, Kalimantan Utara
Cluster 3: Jawa Timur, Jawa Tengah, Jawa Barat, Banten

Berdasarkan hasil pengelompokan menggunakan Fuzzy CMeans ternyata model mampu mengelompokkan provinsi-provinsi di Indonesia ke dalam tiga klaster, meskipun caranya masih saling tumpang tindih menurut pola konsumsi listriknya. Cluster 1 (klaster ungu) yang mencakup DKI Jakarta yang memiliki konsumsi listrik tinggi sebagai pusat ekonomi. Cluster 3 (klaster kuning) yang terdiri dari provinsi urban atau berkembang dan memiliki karakteristik konsumsi listrik yang tinggi antara lain Jawa Barat, Jawa Timur, dan Banten. Sementara itu, cluster 2 (klaster hijau) yang terdiri atas provinsi-provinsi dengan konsumsi listrik rendah dan tersebar, contohnya Aceh, Sumatera Utara, dan Papua, merepresentasikan wilayah pedesaan atau dengan tingkat perkembangan yang tertinggal. Walau Fuzzy C-Means mampu menangani tumpang tindih data dengan memberikan fleksibilitas pengelompokkan provinsi yang memiliki pola konsumsi listrik yang serupa, model ini tetap memberikan kelemahan pada titik cluster 2 yang hanya berjumlah satu yang memisahkan diri dari klaster lainnya dan menunjukkan kondisi overfitting. Salah satu penyebab dari kejadian ini adalah pemaksakan jumlah klaster yang tidak optimal, di mana akan membuat cluster 2 menjadi terpisah dari klaster mayoritas dengan hanya memiliki satu titik. Ini bisa diartikan bahwa Cluster 2 harusnya tidak ada, karena hanya terbentuk akibat model yang terlalu memaksakan supaya hasil silhouette scorenya terbaik.

XMeans



Berdasarkan hasil grafik t-SNE diatas menunjukan adanya 6 cluster yang terbentuk tetapi yang terbentuk, pertama cluster ungu tua yang ada di bagian kiri atas dan lebih terpusat menunjukan konsumsi listrik yang lebih rendah dan mirip antar titiknya. Cluster biru tersebar dengan karakteristik konsumsi listrik yang tersebar secara geografis. Lebih lanjut, cluster hijau terpusat dengan distribusi yang lebih merata berada di tengah, yang menunjukkan konsumsi listrik yang lebih tinggi namun dengan variasi. Pada ujung kanan, cluster ungu memiliki titik yang lebih terpisah. Di daerah yang sama, cluster tosca yang berada di bagian tengah bawah memiliki titik yang terpisah dan menunjukkan perbedaan pola konsumsi listrik yang lebih jelas. Cluster kuning di sisi kanan menunjukkan titik-titik yang terpusat, yang memperlihatkan konsumsi listrik yang paling tinggi, sebuah klaster yang paling jauh terpusat, yang mengindikasikan daerah yang padat dan berkembang. Secara garis besar xmeans mampu memisahkan data berdasarkan konsumsi dan geografis, dilihat dengan membedakan tingkat konsumsi dan variasi antar-klaster yang jelas.



Berdasarkan hasil visualisasi XMeans dengan UMAP, terdapat enam klaster yang terbentuk dengan jelas masing-masing menunjukkan pola konsumsi listrik yang berbeda. Cluster

biru mencerminkan provinsi dengan konsumsi listrik yang lebih rendah serta menggambarkan wilayah yang lebih pedesaan atau kurang berkembang. Cluster ungu menunjukkan provinsi dengan konsumsi listrik yang lebih rendah namun lebih terpusat di daerah tertentu yang mencakup wilayah dengan urbanisasi rendah. Cluster tosca menggambarkan provinsi dengan konsumsi listrik yang lebih tinggi tetapi lebih terdistribusi, mencerminkan kebutuhan energi yang meningkat meskipun masih ada variasi antar provinsi. Cluster hijau tau yang hanya berisi satu titik menunjukkan provinsi dengan konsumsi listrik tinggi yang lebih terfokus yang mencerminkan wilayah dengan urbanisasi lebih tinggi. Cluster kuning mencerminkan provinsi yang memiliki konsumsi listrik sangat tinggi, yang terletak di wilayah industri dan berkembang pesat. Cluster hijau muda menunjukkan provinsi dengan konsumsi listrik tertinggi dengan berisi satu titik yang mencerminkan wilayah padat penduduk dan kawasan ekonomi yang sangat berkembang, seperti pusat-pusat industri besar.

Model xmeans dipilih untuk mengelompokkan pola konsumsi listrik karena memiliki kemampuan untuk secara otomatis menentukan jumlah cluster yang optimal tanpa perlu ditentukan dari awal serta kemampuannya dalam menangani data yang kompleks dan bervariasi. Serta dapat secara akurat memisahkan provinsi berdasarkan pola konsumsi yang berbeda, namun hasil dari clusteringnya masih terdapat 2 cluster yang hanya memiliki satu provinsi sebagai anggota cluster tersebut yang menandakan model belum cukup baik menentukan k optimalnya secara otomatis dan ini terbukti juga dengan hasil silhouette score yang cukup rendah
Berikut adalah hasil dari clustering XMeans:
Cluster 1:

Aceh, Sumatera Barat, Jambi, Kalimantan Barat, Kalimantan Selatan, Kalimantan Tengah, Sulawesi Utara, Sulawesi Tengah, Papua, Nusa Tenggara Barat, Nusa Tenggara Timur, DI Yogyakarta, Kalimantan Timur, Kalimantan Utara

Cluster 2:

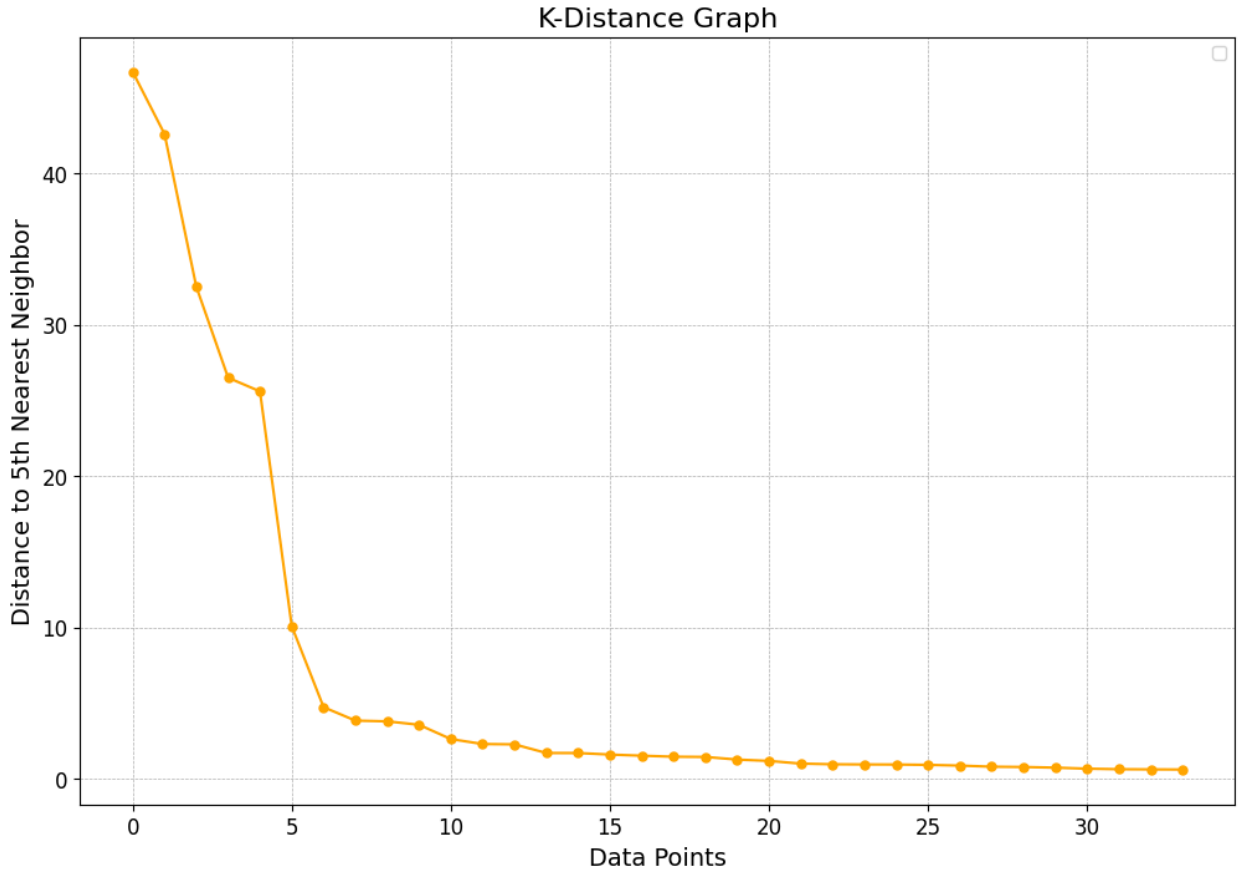
Kep. Riau, Bengkulu, Kep. Bangka Belitung, Gorontalo, Sulawesi Tenggara, Sulawesi Barat, Maluku, Maluku Utara, Papua Barat

Cluster 3: Riau, Sumatera Selatan, Lampung, Sulawesi Selatan, Bali
Cluster 4: Sumatera Utara
Cluster 5: Banten
Cluster 6: Jawa Timur, Jawa Tengah, Jawa Barat, DKI Jakarta

Hasil pengelompokan yang diperoleh dari model XMeans ini terlihat bahwa hasilnya tidak mencerminkan pola konsumsi listrik yang konsisten dengan dengan karakteristik antar cluster dapat dilihat bahwa provinsi yang memiliki tingkat konsumsi yang sama malah dikelompokan kedalam cluster yang berbeda seperti contoh DKI Jakarta ditempatkan terpisah dari Jawa Barat ditambah lagi adanya cluster yang memiliki hanya satu provinsi seperti Banten yang menunjukan sebuah ketidaksesuaian jumlah cluster optimal. Sehingga menunjukan bahwa XMeans tidak berhasil mengidentifikasi pola konsumsi listrik yang relevan dengan dataset kami

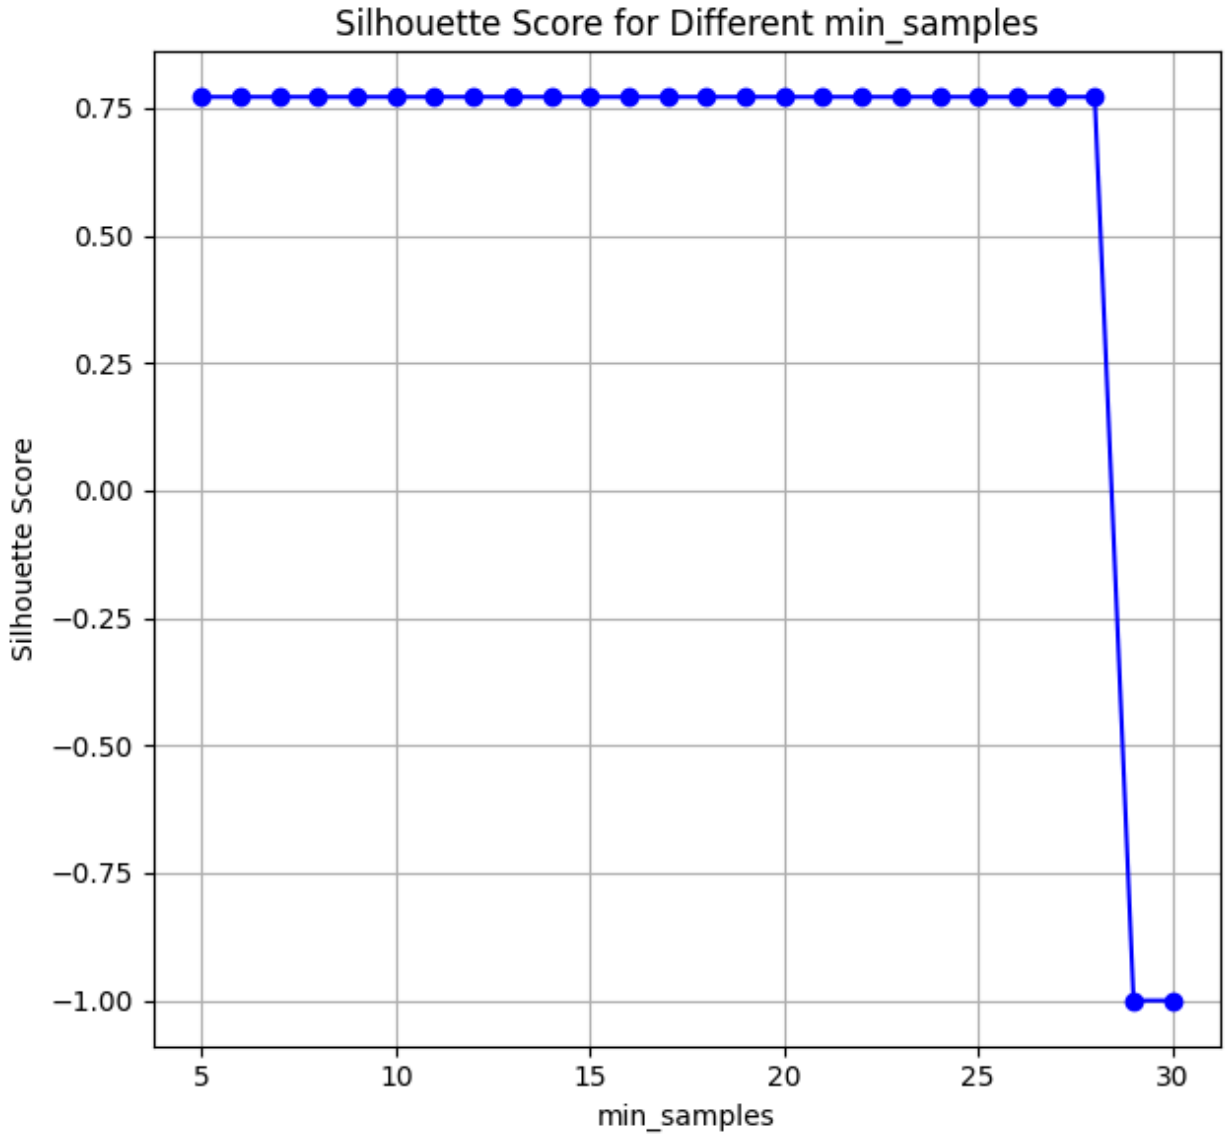
hal ini juga didukung dengan hasil silhouette score yang sangat rendah dengan skor 0.23 yang menunjukan kualitas hasil clustering buruk yang bisa dikatakan ini tidak cocok dengan dataset kami karena tidak menghasilkan hasil yang akurat dan sesuai dengan harapan analisis pola konsumsi setiap provinsi. Ditambah lagi XMeans menentukan jumlah cluster secara otomatis yang cenderung berubah-ubah setiap iterasi dilakukan yang membuat ketidakpastian dalam penentuan jumlah cluster yang nantinya dapat menyebabkan inkonsistensi dalam hasil clustering yang akan memperburuk lagi hasil akurasi model dalam mengelompokan provinsi.

DBSCAN

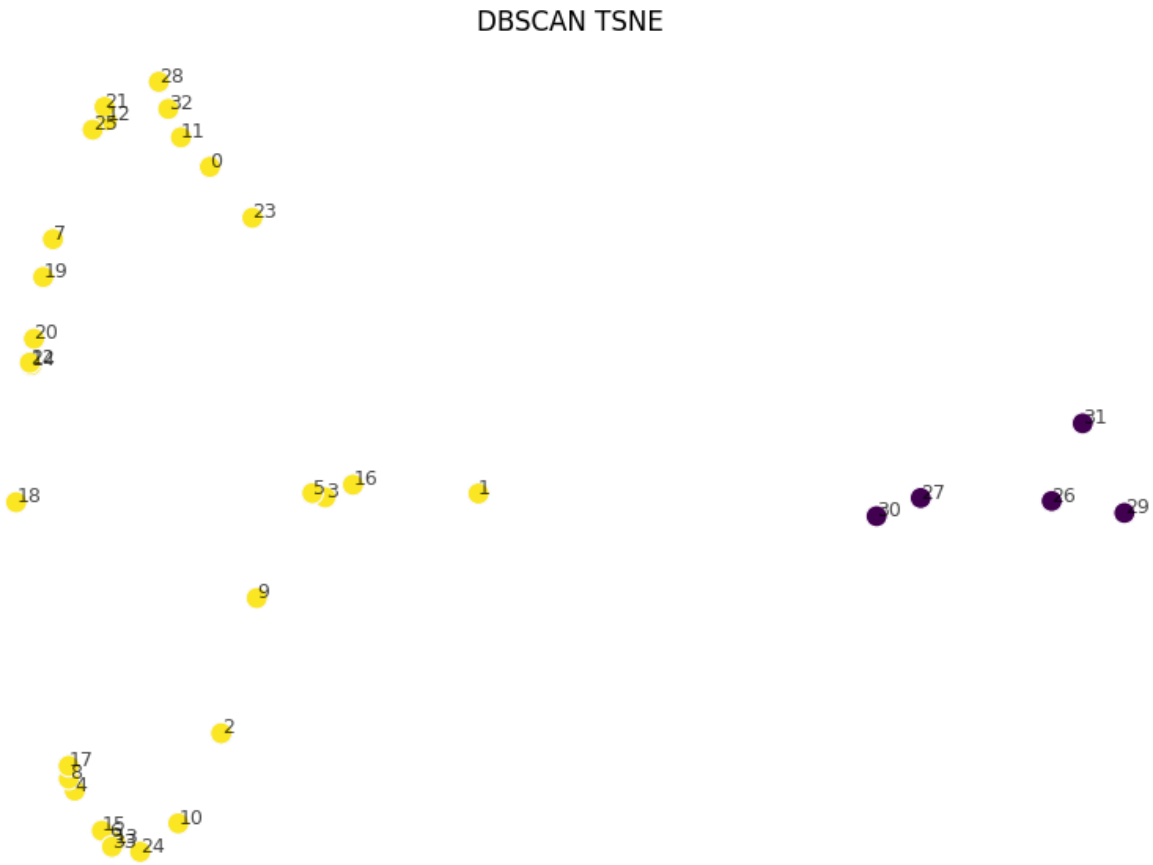


Grafik diatas menunjukan K-Distance untuk menentukan eps terbaik buat di model DBScan untuk clustering pola konsumsi listrik. Grafik ini menunjukan bagaimana kepadatan titik data berubah seiring dengan jarak. Dapat dilihat bahwa jarak awal antar titik cukup besar tetapi kemudian terjadinya penurunan tajam yang mengindikasikan adanya titik infleksi antara data point enam dan 9. Titik infleksi ini akan dijadikan acuan utama untuk menentukan nilai eps,

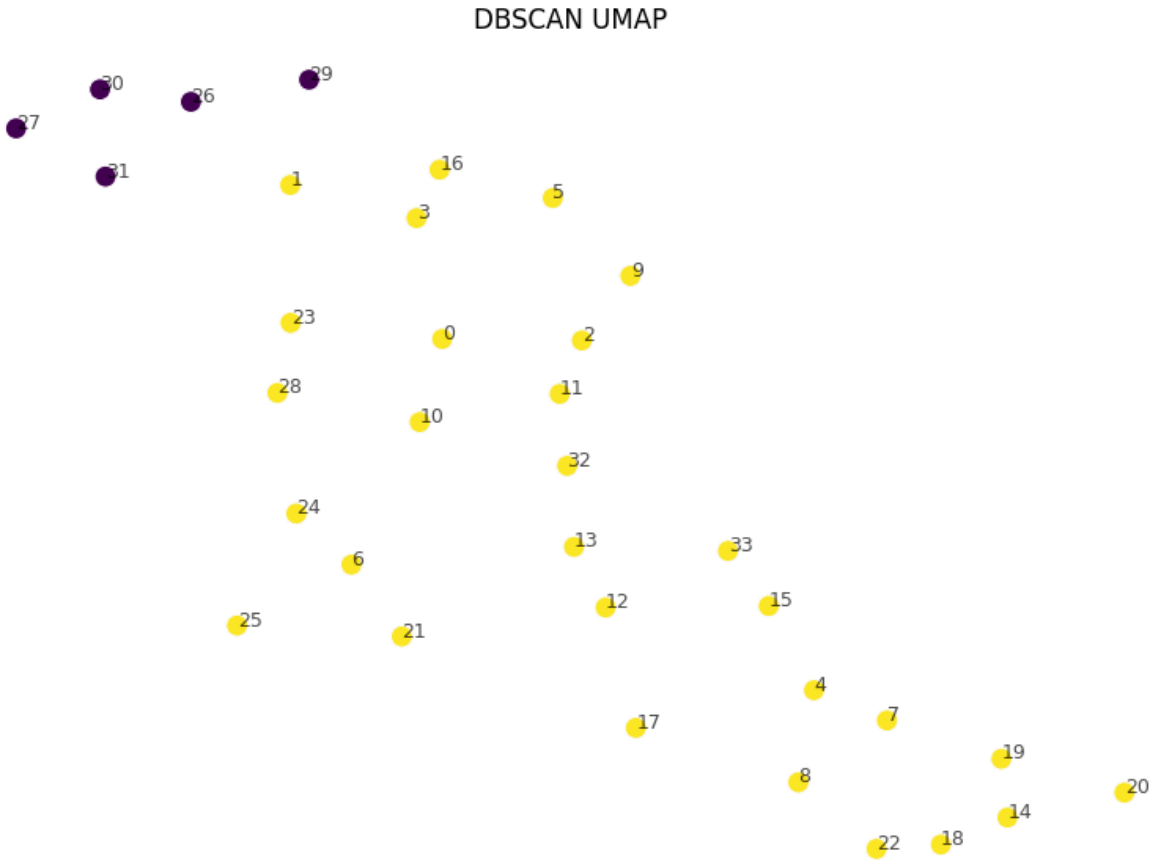
biasanya dipilih pada jarak yang mencakup area sebelum menjadi stabil dan mendatar dengan demikian nilai eps yang diperoleh akan digunakan untuk kedalam model DBScan nantinya.



Grafik diatas untuk menunjukan min samples terbaik agar silhouette scorenya tetap stabil dapat dilihat bahwa score tetap stabil di sekitar 0.75 jika min sampelnya tidak lebih dari 26 kemudian akan mengalami penurunan tajam hingga mendekati -1 hal ini menunjukan bahwa jumlah min samples harus berada di sekitar 10 sampai dengan 25. Jika min sampel terlalu kecil dan membawa dampak buruk yaitu dapat menyebabkan cluster kecil yang terbentuk yang menyebabkan pengelompokan yang terlalu terfragmentasi dengan banyak cluster yang sebenarnya tidak bermakna. Selain itu juga peningkatan noise yang artinya ketika data ternyata adalah outlier malah dianggap kedalam cluster dan juga dapat menyebabkan model gagal mengenali hubungan yang lebih besar antar data untuk membuat pembagian cluster.



Graf diatas menunjukan hasil t-SNE menghasilkan dua cluster dengan jelas, cluster ungu terdiri dari titik-titik yang terpisah dan terkonsentrasi yang menunjukan bahwa kelompok ini memiliki pola konsumsi yang lebih berbeda dari kelompok lainnya. Sedangkan cluster kuning lebih tersebar dengan beberapa titik dekat satu sama lain yang menunjukan kesamaan pola konsumsi listrik yang lebih serupa. Serta sebagian besar data termasuk kedalam cluster ini yang mengindikasikan dipengaruhi oleh beberapa faktor yang seragam contohnya tingkat urbanisasi, kebijakan energi, dan faktor sosial ekonomi yang homogen. Cluster kuning mewakili kelompok provinsi yang memiliki konsumsi listrik yang lebih stabil dan teratur sedangkan cluster ungu menggambarkan pola konsumsi yang fluktuatif yang artinya memiliki faktor yang menyebabkan tingkat penggunaan listrik yang besar.



Graf diatas menunjukan hasil visualisasi DBSCAN menggunakan UMAP dapat terlihat terbagi menjadi dua cluster. Cluster ungu berada diatas dan lebih kecil dan terpisah yang menunjukan bahwa kelompok ini memiliki pola konsumsi yang tinggi. Cluster ini mencerminkan provinsi dengan pola konsumsi listrik yang memiliki kebutuhan tinggi karena banyaknya wilayah industri dan jumlah penduduk. Cluster kuning tersebar dan memiliki banyak titik yang cukup berdekatan yang artinya faktor yang mempengaruhi setiap provinsi hampir serupa hal yang membuat menjadi serupa seperti ketergantungan pada sumber daya energi yang serupa serta kebijakan yang seragam membuat konsumsi listrik di provinsi-provinsi ini konsisten.
Berikut adalah hasil dari clustering DBSCAN :

Outliers:
Jawa Timur, Jawa Tengah, Jawa Barat, Banten, DKI Jakarta

Cluster 0:
Aceh, Sumatera Utara, Sumatera Barat, Riau, Kep. Riau, Sumatera Selatan, Jambi, Bengkulu, Kep. Bangka Belitung, Lampung, Kalimantan Barat, Kalimantan Selatan, Kalimantan Tengah, Sulawesi Utara, Gorontalo, Sulawesi Tengah, Sulawesi Selatan, Sulawesi Tenggara, Sulawesi

Barat, Maluku, Maluku Utara, Papua, Papua Barat, Bali, Nusa Tenggara Barat, Nusa Tenggara Timur, DI Yogyakarta, Kalimantan Timur, Kalimantan Utara

DBSCAN sangat cocok untuk analisis pengelompokan provinsi di Indonesia berdasarkan pola konsumsi listrik karena memiliki kemampuan untuk mendeteksi outlier dan mengelompokan data berdasarkan kepadatan yang sesuai dengan dataset kami yang mempunyai outlier. Tujuan utama dari model ini selaras dengan hasil yang diharapkan yaitu mengidentifikasi provinsi-provinsi di pulau Jawa seperti Jawa Timur, Jawa Tengah, Jawa Barat, Banten dan Jakarta yang menunjukan pola konsumsi tinggi dibandingkan dengan provinsi di luar jawa dan provinsi ini dideteksi sebagai outlier yang menunjukan adanya ketimpangan yang jelas dalam distribusi listrik yang ada di Indonesia dimana jawa yang menjadi pusat utama dalam konsumsi listrik sementara daerah lain polanya seragam.

	Model	Jumlah Cluster	Silhouette Score
0	KMeans	2	0.809868
1	XMeans	6	0.381790
2	FCM	3	0.813461
3	DBSCAN	2	0.809868
4	KMEDOIDS	3	0.813461

Berdasarkan hasil silhouette score, model Fuzzy C-Means dan KMedoids menunjukkan kinerja terbaik dengan skor masing-masing 0.813461, yang mengindikasikan bahwa keduanya berhasil membentuk cluster yang sangat baik dengan pemisahan yang jelas dan kohesi data yang tinggi. Di sisi lain, XMeans memiliki skor rendah 0.381790, menunjukkan bahwa clustering yang dihasilkan kurang efektif dengan data yang tersebar. Sementara itu, KMeans dan DBSCAN, keduanya memiliki skor yang sama 0.809868, menunjukkan kinerja yang serupa dalam menghasilkan cluster yang cukup baik, meskipun DBSCAN juga memiliki kelebihan dalam mendeteksi outlier. Secara keseluruhan, FCM dan KMedoids lebih unggul dalam hal kualitas clustering dibandingkan dengan model lainnya. Tetapi perlu diingat hasil silhouette score lebih baik belum tentu merupakan yang terbaik dalam kualitas cluster karena di KMedoids maupun Fuzzy CMeans ada satu cluster yang hanya terdiri dari satu provinsi maka ini kurang baik dalam menunjukan karakteristik tersebut sehingga mungkin adanya terjadi overfitting ataupun deteksi outlier yang gagal.

Keunggulan DBSCAN dibandingkan dengan cluster KMeans yaitu DBSCAN tidak perlu menentukan jumlah cluster sebelumnya sedang KMeans mengharus untuk penentuan jumlah cluster yang akan menyulitkan dalam pendistribusian data yang tidak merata atau outliernya besar. Meskipun hasil terbaik dari KMeans sama persis seperti DBSCAN tetapi tidak terdeteksi outlier yang merupakan penjelasan kurang menekankan ketimpangan yang terjadi. Sedangkan Dibandingkan dengan XMeans yang menentukan jumlah cluster secara otomatis tetapi tetap bergantung pada pembagian data berdasarkan jarak dan asumsi distribusi data yang lebih seragam serta hsil dari XMeans enam cluster yang tidak dapat menjelaskan perbedaan karakteristik dari setiap cluster dengan jelas tentang pola konsumsi listrik sedangkan DBSCAN lebih fleksibel dan dapat dengan jelas membedakan provinsi-provinsi di Jawa memiliki perbedaan jelas dibandingkan dengan provinsi di luar Jawa.

Dibandingkan dengan FuzzyCMeans yang memungkinkan data menjadi bagian dari beberapa cluster dengan memberikan bobot pada setiap titik sedangkan DBSCAN lebih unggul karena bisa mendeteksi outlier dan mengelompokan data berdasarkan tingkat kepadatan yang jelas.FuzzyCMeans berhasil memperoleh silhouette score terbaik yaitu 0.8134 dengan tiga cluster tetapi di satu cluster tersebut ada yang hanya berisi satu provinsi yaitu DKI Jakarta padahal setelah di lihat pola konsumsi Jakarta sama seperti provinsi lain yang ada di Jawa sehingga ini mengindikasikan tidak tergambar jelas pola konsumsi listrik antar provinsinya.Dibandingkan dengan KMedoids yang menggunakan titik data yang sebenarnya sebagai cluster pusat serta dalam melakukan pemodelan KMedoids diperlukan penentuan jumlah cluster dan memiliki keterbatasan dalam fleksibilitas serta rentan terhadap noise ini terbukti pada data hasil clusternya tiga tetapi terdapat satu cluster yang hanya berisi satu provinsi yang menunjukan adanya overfitting sehingga DBSCAN lebih baik karena bisa mengidentifikasi outliers.

Sehingga DBSCAN bisa dibilang cocok dengan tujuan kami karena adanya keselarasan yang terjadi baik itu dalam dataset yang terdapat outlier sehingga cocok serta kami ingin secara eksplisit melihat provinsi mana saja yang mengalami ketimpangan pola konsumsi listrik yang terjadi di Indonesia dengan hasil yang ditunjukkan oleh DBSCAN bahwa Provinsi yang ada di Jawa dideteksi sebagai outlier menekankan bahwa memang betul adanya ketimpangan nilai yang cukup besar sehingga terdeteksi sebagai outlier.

F. Demo

https://huggingface.co/spaces/vel740/mlkonsumsilistrikv1.1

G. Kesimpulan

Berdasarkan hasil analisis menggunakan DBSCAN menunjukan bahwa model ini sangat efektif dalam mengindetifikasi ketimpangan distribusi listrik yang terjadi di Indonesia. DBSCAN dapat dengan jelas membedakan provinsi di Jawa sebagai outlier yang menunjukan pola

konsumsi listrik disini jauh lebih tinggi dibandingkan dengan di luar Jawa yang memiliki pola konsumsi searagam Keunggulan DBSCAN dibandingkan dengan model lainnya dapat mendeteksi outlier secara otomatis tanpa memerlukan jumlah cluster sebelumnya. Model ini akan membantu karena menyoroti ketimpangan yang ada sehingga pemerintah dapat menggunakannya untuk merumuskan kebijakan energi listrik lebih merata terutama di luar Jawa yang berguna juga untuk merencanakan pengalokasian sumber daya listrik yang adil dan efisien di seluruh provinsi Indonesia tanpa terkecuali.

H. Referensi

1. Hafiizh, M., Prasetyo, M.W. & Prasetya, D.D., 2024. Analisis Penggunaan Listrik PLN di Jawa Timur Menggunakan Algoritma K-Medoids. Jurnal Riset dan Aplikasi Mahasiswa Informatika (JRAMI), 5(2), pp.367-375.
2. Mulyadi, S., Insani, F., Agustian, S. & Afriyanti, L., 2024. Grouping Electricity Distribution Data Using The Mini Batch K-Means Clustering Algorithm. MALCOM: Indonesian Journal of Machine Learning and Computer Science, 4(3), pp. 1051-1062.
3. Rusnedy, H., Nurcahyo, G.W. & Sumijan, 2021. Identifikasi Tingkat Pemakaian Obat Menggunakan Metode Fuzzy C-Means. Jurnal Informasi dan Teknologi, 3(4), pp.196-204.
4. Wijayanto, A. & Adhitama, R., 2019. Penggunaan X-Means Clustering Method untuk Mengelompokkan Potensi Sekolah Menengah Unggul di Kabupaten Banyumas. Journal of Informatics, Information System, Software Engineering and Applications (INISTA), 2(1), pp. 80-88.
5. Farid, M., Insani, F., Agustian, S. & Afriyanti, L., 2024. Pengelompokan Data Pendistribusian Listrik Menggunakan Algoritma Density-Based Spatial Clustering of Application With Noise (DBSCAN). MALCOM: Indonesian Journal of Machine Learning and Computer Science, 4(3), pp. 1026-1035.
6. Dataset Jumlah penduduk https://sulut.bps.go.id/id/statistics-table/2/OTU4IzI=/jumlah-penduduk-menurut-provinsi-diindonesia.html
7. Dataset Konsumsi Listrik 2021 https://web.pln.co.id/statics/uploads/2022/09/Statistic-PLN-2021-English-8-9-22.pdf
8. Dataset Konsumsi Listrik 2022 https://web.pln.co.id/statics/uploads/2023/05/Statistik-PLN-2022-Final-2.pdf
9. Dataset Konsumsi Listrik 2023 https://web.pln.co.id/statics/uploads/2024/08/Bk-Statistik-PLN-2023-English-31.7.24.pdf
10. Link model https://github.com/XQVWMM/konsumsi-listrik-notebook.git
11. Link deploy app https://github.com/yuu740/MLKonsumsiListrik.git
12. Link ppt https://www.canva.com/design/DAGplVtyl4o/C1XXPq7abUQegjV81hQGQQ/edit?utm_

content=DAGplVtyl4o&utm_campaign=designshare&utm_medium=link2&utm_source=sharebutton